

Санкт-Петербургский государственный университет

Информационно-аналитические системы

Группа 22.М04-мм

*Екатерина Петровна Винник*

# Прогнозирование отказов жестких дисков системы Tatlin.Unified

Отчёт по производственной практике

Научный руководитель:  
к.ф.-м.н., В.И. Гориховский

Санкт-Петербург  
2023

Saint Petersburg State University

Software and Administration of Information Systems

Group 22.M04-mm

*Ekaterina Vinnik*

# Failure Prediction in Tatlin.Unified Hard Disk Drives

Internship report

Scientific supervisor:  
C.Sc. V. I. Gorikhovskii

Saint Petersburg  
2023

# Оглавление

<b>Введение</b>	<b>4</b>
<b>Постановка задачи</b>	<b>6</b>
<b>1. Существующие подходы к прогнозированию отказа жесткого диска</b>	<b>7</b>
1.1. Прогнозирование отказа жесткого диска с помощью решения задачи бинарной классификации . . . . .	7
1.2. Прогнозирование отказа жесткого диска с помощью решения задачи выявления аномалий . . . . .	9
1.3. Прогнозирование отказа жесткого диска с помощью решения задачи кластеризации . . . . .	12
<b>2. Применение подходов на наборе модельных данных</b>	<b>17</b>
2.1. Выбор набора модельных данных . . . . .	17
2.2. Применение алгоритмов бинарной классификации . . . .	18
2.3. Применение алгоритмов выявления аномалий . . . . .	21
2.4. Применение алгоритмов кластеризации . . . . .	22
2.5. Анализ примененных подходов . . . . .	26
<b>3. Применение подходов на реальных данных</b>	<b>27</b>
3.1. Формирование набора данных . . . . .	27
3.2. Кластеризация сформированного набора данных . . . . .	31
3.3. Анализ выявленного кластера . . . . .	34
<b>Заключение</b>	<b>36</b>
<b>Список литературы</b>	<b>38</b>

# Введение

Жесткие диски являются одним из самых распространенных устройств хранения и присутствуют в разных системах — от персональных компьютеров до систем хранения данных. Согласно [9], большинство информации, производимой в мире, хранится на жестких дисках. Частота отказов жесткого диска в год составляет чуть меньше 1% [25], что не удовлетворяет большое количество пользователей, так как в некоторых высоко масштабируемых системах, например, в центрах обработки данных или поставщиках интернет-услуг количество жестких дисков в одном вычислительном узле может легко достигать тысячи [1]. Отказ каждого из этих жестких дисков может не только увеличить время простоя сервиса, но и привести к потере данных. Задача предсказания отказа жесткого диска является актуальной и для жестких дисков систем хранения данных компании YADRO, которая, согласно данным отчета корпорации IDC (INTERNATIONAL DATA CORPORATION), является лидером российского рынка внешних систем хранения данных в емкостном выражении с долей 63.7%<sup>1</sup>. На данный момент компания YADRO разрабатывает семейство систем хранения данных TATLIN — TATLIN.ARCHIVE, TATLIN.UNIFIED, TATLIN.OBJECT. Так как для систем хранения данных семейства TATLIN прогнозирование отказов жестких дисков не производится, поддержка прогнозирования позволила бы повысить надежность и эффективность хранения данных в этих системах.

Существующая широко применяемая технология прогнозирования отказа жесткого диска S.M.A.R.T. (*self-monitoring, analysis and reporting technology*) заключается в отслеживании значений набора параметров на предмет превышения соответствующих пороговых значений. Хотя эта технология широко используется, частота предсказания отказов диска с ее помощью является достаточно низкой — ввиду стремления ее создателями снизить количество ложных положительных классификаций, технология S.M.A.R.T. позволяет предсказать от 3% до 10% отказов [15][16][11].

---

<sup>1</sup><https://st.yadro.com/docs/idc-whitepaper-rus.pdf> Дата последнего обращения 27.12.2022

Для повышения частоты предсказания отказа дисков разрабатывались разные подходы, использующие в своей основе данные о поведении диска, собираемые с помощью технологии S.M.A.R.T.. Большинство этих подходов заключается в применении методов машинного обучения к данным, собираемым технологией S.M.A.R.T. [7][15][18][28][29]. Это связано с тем, что задача прогнозирования отказа диска является задачей бинарной классификации, которая в свою очередь является одной из самых распространенных задач, решаемых с помощью алгоритмов машинного обучения.

Ввиду того, что было разработано большое количество подходов для прогнозирования отказов жестких дисков, для поддержки прогнозирования отказов дисков системы хранения данных TALIN.UNIFIED целесообразно сначала произвести анализ разработанных подходов. Применение набора подходов для прогнозирования отказа жестких дисков системы хранения данных TALIN.UNIFIED с последующим сравнением результатов, полученных с помощью этих подходов, позволит выбрать наилучший подход для прогнозирования отказа жестких дисков и интегрировать его, повысив тем самым надежность хранения данных системы.

# Постановка задачи

Целью данной работы является поддержать прогнозирование отказов жестких дисков в системе хранения данных TATLIN.UNIFIED.

Для достижения этой цели в рамках производственной практики были поставлены следующие задачи.

- Произвести обзор предметной области;
- Выбрать набор модельных данных и исследовать его, сформулировав ряд закономерностей, характеризующих данные;
- Применить существующие подходы на наборе модельных данных;
- Использовать рассмотренные подходы на реальных данных жестких дисков системы TATLIN.UNIFIED;
- Произвести сравнение примененных к прогнозированию отказов жестких дисков системы TATLIN.UNIFIED подходов;

В рамках дальнейшей работы планируется выполнить следующие задачи:

- Интегрировать наилучший подход к прогнозированию отказов жестких дисков в систему TATLIN.UNIFIED.

# **1. Существующие подходы к прогнозированию отказа жесткого диска**

Существует несколько различных идей, которые могут использоваться для прогнозирования отказа жесткого диска – кластеризация, бинарная классификация, выявление аномалий.

## **1.1. Прогнозирование отказа жесткого диска с помощью решения задачи бинарной классификации**

### **1.1.1. Использование байесовского классификатора**

Применение наивного байесовского классификатора [7] являлось одной из первых попыток применения методов машинного обучения к прогнозированию отказов жестких дисков. В данном исследовании было сделано предположение о том, что отказ жесткого диска невозможно спрогнозировать менее, чем за 48 часов до его отказа. На основе этого предположения класс отказавших жестких дисков был сформирован из записей, относящихся к последним 48 часам наблюдений за параметрами жесткого диска. Применение этого метода дало достаточно низкую точность классификации — доля верных положительных классификаций составила 0.33 при доле 0.001 ложных положительных классификаций. Более поздние исследования применимости этого подхода к прогнозированию отказов жестких дисков дали сходные результаты [8].

Также для прогнозирования отказа жесткого диска использовался древовидный алгоритм Байеса [27], который показал 80% верных положительных классификаций при 3% ложных положительных классификаций. Однако при попытке снизить количество ложных положительных классификаций до 0% частота верных положительных классификаций алгоритма снизилась до 20-30%.

### 1.1.2. Использование метода опорных векторов

Метод опорных векторов, предложенный в [29], заключается в проектировании исходного набора векторов данных в пространство более высокой размерности и последующем поиске оптимальной разделяющей гиперплоскости [29]. Этот метод также одним из первых стал применяться для прогнозирования отказов дисков [15][16] и позволил классифицировать 50.6% отказов жестких дисков при 0% ложных положительных классификаций. Однако метод требует больших вычислительных ресурсов, и поэтому распространения в предсказывании отказов жестких дисков в режиме реального времени не получил.

### 1.1.3. Использование скрытой марковской модели

Хотя скрытые марковские модели, предложенные Баумом в 1966 [2], исторически широко применялись для задач распознавания речи, алгоритмы машинного обучения на основе марковских моделей были применены и для прогнозирования отказа жесткого диска [20]. В исследовании [20] авторы рассмотрели последовательности значений параметров жесткого диска, измеренных в последовательные промежутки времени и применили скрытые марковские модели для моделирования этих последовательностей. Подход с использованием скрытой марковской модели позволил достичь 52% положительных классификаций при 0% ложных положительных классификаций, что сравнимо с результатом, полученным с помощью метода опорных векторов.

### 1.1.4. Метод $K$ ближайших соседей

Метод  $K$  ближайших соседей, представленный в [5] — это метрический алгоритм классификации, основанный на вычислении оценок сходства между объектами. Для предсказания целевого признака для нового объекта  $x$  производятся следующие шаги:

- Вычисляются расстояния от  $x$  до всех объектов обучающей выборки;



- Объекты обучающей выборки сортируются по возрастанию расстояний до  $x$ ;
- Выбираются  $k$  объектов с наименьшими расстояниями до  $x$ ;
- По этим  $k$  объектам вычисляется ответ на задачу предсказания.

Данный метод, примененный для решения задачи классификации отказа жесткого диска [19], позволил идентифицировать наибольшее по сравнению с остальными методами количество отказов жестких дисков — 97% при 0.3% ложных положительных классификаций.

### 1.1.5. Метод случайного леса

Метод случайного леса, заключающийся в использовании набора решающих деревьев для решения задачи классификации, был представлен в [3] и сочетает в себе применение метода бэггинга для построения ансамбля деревьев и метода случайных подпространств.

Примененный для прогнозирования отказов жестких дисков, он показал худшие результаты по сравнению с методом  $K$  ближайших соседей, позволив идентифицировать 94.3% отказов дисков при 0.4% ложных положительных классификаций. Тем не менее этот результат является вторым по количеству идентифицированных отказавших дисков среди рассмотренных подходов при одном из самых низких процентов ложных положительных классификаций.

## 1.2. Прогнозирование отказа жесткого диска с помощью решения задачи выявления аномалий

Хотя с помощью решения соответствующей задачи бинарной классификации для прогнозирования отказа дисков было разработано множество подходов, алгоритмы классификации являются алгоритмами обучения с учителем, то есть, требуют наличие на наборе данных разметки. В случае прогнозирования отказа дисков это означает, что для

всех наблюдений собранных дисковых данных требуется также отметить, было это наблюдение сделано при сломанном диске, или при корректно работающем. В больших корпоративных системах, имеющих множество дисков, определить на лету, сломан тот или иной диск, очень трудно и ресурсоемко, поэтому наборы данных таких систем скорее всего не будут содержать разметку. Отсутствие разметки на реальных данных приводит к необходимости изучения методов машинного обучения, не ориентирующихся на разметку, для прогнозирования дисков. Одним из таких подходов является интерпретация поведения близкого к поломке диска как аномалии, возникшей у корректно работающего диска. В такой интерпретации решение задачи прогнозирования отказа жесткого диска означает решение задачи выявления аномалий среди жестких дисков.

### **1.2.1. Isolation Forest**

Выявление аномалий с помощью алгоритма изолированного леса, представленного в [12], было применено к прогнозированию отказов жестких дисков сравнительно недавно [23]. Алгоритм изолированного леса использует ансамбль деревьев и заключается в рекурсивном разделении набора данных по значению какого-либо случайно выбранного на текущем этапе признака. Так, в результате некоторого числа итераций разделения набора данных, будет образовано дерево, а длина пути от корня до листа, в котором находится тот или иной фрагмент рассматриваемых данных, характеризует степень аномальности этих данных. При случайном рекурсивном разбиении набора данных аномалии как правило имеют более короткие пути от корня дерева к листу, чем остальные элементы (ввиду того, что на определенном шаге алгоритма аномальные наблюдения будут изолированы от остальных по значению какого-либо признака). Алгоритм изолированного леса использует ансамбль деревьев, и в случае, если для ряда деревьев ансамбля какие-то элементы из набора данных имеют маленькое значение длины пути, скорее всего, они будут признаны аномальными. Данный подход показал результаты, значительно превосходящие результаты метода опор-

ных векторов — 84.54% положительных классификаций при 0.0073% ложных положительных классификаций. Также стоит отметить, что хотя доля положительных классификаций у этого метода ниже, чем, например, у алгоритма случайного леса, доля ложных положительных классификаций у этого подхода значительно ниже, чем соответствующая доля ложных положительных классификаций алгоритма случайного леса: 0.0073% против 0.4%.

### **1.2.2. Использование расстояния Махаланобиса**

Подход, использующий расстояние Махаланобиса [18] [31] для прогнозирования отказов жестких дисков, основан на вычислении расстояния Махаланобиса — обобщенном расстоянии, позволяющем измерить сходство между новым наблюдением и набором уже известных наблюдений с помощью рассмотрения корреляций между наблюдениями. Вычисленные значения расстояния Махаланобиса используются четырьмя оценщиками для вычисления значений, сравниваемых с пороговыми. Диск считается отказавшим, если результирующее значение какого-либо из оценщиков превысило пороговое значение.

Данный подход показал результаты, превосходящие метод опорных векторов — 67% положительных классификаций при 0% ложных положительных классификаций. Также подход, использующий расстояние Махаланобиса значительно опередил метод опорных векторов в вычислительной скорости, показав 4.3 минуты против 17983 минут, достигнутых методом опорных векторов. Этот показатель очень важен, так как низкая производительность метода опорных векторов являлась сдерживающим фактором в его использовании для прогнозирования отказов дисков на системах в режиме реального времени. Подход, использующий расстояние Махаланобиса, также позволил предсказать 56% отказов жестких дисков за 20 часов до отказа.

### **1.2.3. Использование автокодировщиков**

Автокодировщики достаточно часто используются для выявления аномалий [14][32][24], и в частности они применяются и для выявления отказов жестких дисков [28]. В исследовании [28] рассмотрено несколько подходов к использованию автокодировщиков для выявления отказов жестких дисков.

Первый из подходов, описанных в [28] использует для классификации наличия отказа диска размер ошибки восстановления — если ошибка восстановления превышает пороговое значение, считается, что произошел отказ жесткого диска. Второй из подходов, описанных в [28] заключается в проверке сходства очередного объекта тренировочной выборки с остальными объектами в пространстве меньшей размерности с использованием расстояния Махаланобиса для измерения сходства. В случае, если расстояние Махаланобиса для очередного объекта превысило пороговое значение, считается, что произошел отказ жесткого диска. Третий подход, описанный в [28], является комбинацией метрик предыдущих двух подходов. Третий подход показал наибольшую частоту положительных классификаций по сравнению с первыми двумя — 28.09% при 10% ложных положительных классификаций. Результатов применения подходов при 0% ложных положительных классификаций представлено не было.

## **1.3. Прогнозирование отказа жесткого диска с помощью решения задачи кластеризации**

Еще одним потенциально интересным подходом к прогнозированию отказов жестких дисков, не требующим разметки, является кластеризация данных. Кластеризация не применялась к прогнозированию жестких дисков ранее, но высокие результаты кластеризации данных дисков могли бы продемонстрировать наличие определенных моделей поведения дисков в рассматриваемом наборе данных. Низкие результаты кластеризации напротив демонстрируют невозможность выделить

определенные поведения дисков, и в частности, выделить отказывающиеся диски.

### 1.3.1. KMeans

Алгоритм *KMeans* [13] группирует данные, пытаясь разделить выборки на  $n$  групп с одинаковой дисперсией, сводя к минимуму инерцию (*inertia*). Полагая, что *KMeans* разделяет набор данных из  $N$  элементов  $X$  на  $K$  не пересекающихся кластеров  $C$ , каждый из которых описывается средним  $\mu_j$  элементов кластера, инерцию можно определить следующим образом:

$$\sum_{i=0}^n \min_{\mu_j \in C} (\|x_i - \mu_j\|^2) \quad (1)$$

Средние  $\mu_j$  кластеров также называются центроидами. Недостатком алгоритма *KMeans* является то, что он требует указание количества кластеров для своей работы, которое влияет на качество полученной кластеризации. Оптимальное количество кластеров может варьироваться в зависимости от набора данных, на котором предполагается проводить кластеризацию.

### 1.3.2. Bisecting KMeans

Алгоритм *BisectingKMeans* [4] является итеративным вариантом алгоритма *KMeans*, использующим разделяющую иерархическую кластеризацию. Вместо задания всех центроидов одновременно как это происходит в *KMeans*, центроиды выбираются динамически на основе результатов предыдущей кластеризации: кластер разбивается на два новых кластера до тех пор пока не будет достигнуто целевое количество кластеров.

### 1.3.3. Mean Shift

Алгоритм *MeanShift* направлен на обнаружение скоплений в наборе наблюдений равномерной плотности. Это алгоритм, основанный на

итеративной корректировке центроидов таким образом, чтобы они были средним значением точек в заданной области. Затем эти центроиды фильтруются на этапе постобработки, чтобы исключить близкие к дубликатам центроиды и сформировать окончательный набор центроидов.

Положение центроидов корректируется с использованием метода, называемого восхождением на холм, который находит локальные максимумы расчетной плотности вероятности. Пусть на итерации  $t$  имеется центроид  $x$ , тогда центроид на итерации  $t + 1$  может быть вычислен следующим образом:

$$x^{t+1} = x^t + m(x^t) \quad (2)$$

где  $m$  есть сдвиг среднего значения. Пусть  $K(x_i - x)$  — ядерная функция,  $N(x)$  — окрестность  $x$ , то есть, набор точек, для которых  $N(x_i) \neq 0$ . Тогда сдвиг среднего значения  $m$  задается формулой 3.

$$m(x) = \frac{\sum_{x_i \in N(x)} K(x_i - x)x_i}{\sum_{x_i \in N(x)} K(x_i - x)} \quad (3)$$

Этот алгоритм не слишком хорошо масштабируется, так как требует поиска множества соседей на каждой итерации в процессе своей работы. В отличие от *KMeans* и *BisectingKMeans* не требует задания количества кластеров для проведения кластеризации.

#### 1.3.4. OPTICS

Алгоритм упорядочения точек для обнаружения кластерной структуры (*Ordering points to identify clustering structure, OPTICS*), представленный в [17] кластеризует данные на основе плотности. Он принимает на вход параметр  $\epsilon$ , а также параметр *MinPts* — минимальное число точек, необходимое для образования кластера. Точка  $P$  называется основной точкой, если в ее окрестности  $N_\epsilon(p)$  находятся минимум *MinPts* точек. Алгоритм состоит из следующей последовательности шагов:

- Выбирается случайная точка  $P$

- Вычисляются все точки, находящиеся в ее  $N_\epsilon(p)$  окрестности и кладутся в очередь
- Найденным точкам присваиваются значения достижимости до основной точки и расстояние досягаемости
- В случае, если  $P$  — не основная точка, берется следующая точка из очереди и процесс повторяется сначала
- В случае, если  $P$  — основная точка, для каждой точки  $q$  в  $N_\epsilon(p)$  обновляется ее расстояние досягаемости до основной точки. Все непосещенные ранее точки  $q$  складываются в очередь для дальнейшей обработки.
- В результате посещения всех точек алгоритмом получается набор расстояний досягаемости, на основании которых данные кластеризуются.

Данный алгоритм очень хорошо масштабируется и не требует указания количества кластеров для своей работы, поэтому может представить хорошие результаты при работе с таким большим набором данных, как множество параметров различных дисков.

### 1.3.5. Spectral Clustering

Алгоритм спектральной кластеризации, изложенный в [34], заключается в применении стандартных алгоритмов кластеризации (например, *KMeans*) на данных сниженной размерности. Алгоритм получает на вход некоторую матрицу сходства  $S$  размерности  $\mathbb{R}^{n \times n}$  и целевое количество кластеров  $k$  и состоит из следующей последовательности шагов:

- Построить на основе полученной матрицы сходства граф сходства
- Вычислить для построенного графа дискретный оператор Лапласа  $L$
- Вычислить  $k$  собственных векторов  $u_1, \dots, u_k$  из  $Lu = \lambda Du$

- Составить матрицу  $U \in \mathbb{R}^{n \times k}$ , где столбцами являются векторы  $u_1, \dots, u_k$
- Считая  $y_i \in \mathbb{R}^k$  для  $i = 1 \dots n$  строками матрицы  $U$ , провести кластеризацию для  $y_{i=1 \dots n} \in \mathbb{R}^k$  с помощью алгоритма кластеризации (*KMeans*) на кластера  $C_1, \dots, C_k$
- Выдать в качестве результата набор кластеров  $A_1, \dots, A_k$ , где  $A_i = \{j | y_j \in C_i\}$

Алгоритм спектральной кластеризации требует указания количества кластеров, что усложняет его использование, так как оптимальное количество кластеров в кластеризации сильно зависит от набора данных.



## 2. Применение подходов на наборе модельных данных

### 2.1. Выбор набора модельных данных

В большинстве исследований, приведенных в главе 1, применимость разработанных подходов к прогнозированию отказов жестких дисков оценивалась на каком-либо из следующих наборов данных [22]:

- *University of California dataset* (использовался, например, в [16])
- *Baidu dataset* (использовался, например, в [21])
- *Quantum Corporation dataset* (применялся в [19])
- *Backblaze dataset* (упоминался в [22])

Набор данных, предоставленный университетом Калифорнии использовался, например, в работах [15][16]. Недостатком этого набора данных является то, что его признаки не являются непосредственно S.M.A.R.T. параметрами, что снижает применимость выводов, сделанных на основе этого набора данных, к реальным данным, составленным из значений S.M.A.R.T.. Кроме того, набор данных университета Калифорнии был собран достаточно давно и поэтому гипотезы, сделанные на основе этих данных, могут быть не применимы к данным, собранным в настоящее время.

Набор данных корпорации *Quantum* использовался, например, в работе [7]. Так как этот набор данных имеет 11 признаков, соответствующих S.M.A.R.T. параметрам и был собран достаточно давно, гипотезы, опробованные на этом наборе данных, могут быть не применимы к реальным данным жестких дисков, имеющих более 200 S.M.A.R.T. параметров.

Из двух аналогичных наборов данных, предоставленных центрами обработки данных *Baidu* и *Backblaze*, был выбран предобработанный

набор данных<sup>2</sup> на основе данных центра *Backblaze*. Этот набор данных содержит данные одной модели жесткого диска SEAGATE ST4000DM000 и содержит данные о 120 днях работы до отказа для отказавших дисков и 120 произвольных днях работы для дисков, работающих корректно.

Этот набор данных содержал дублирующие друг друга признаки, а также признаки, имеющие константные значения на всем наборе данных, что позволило в результате предобработки сократить количество признаков с 90 до 17.

## 2.2. Применение алгоритмов бинарной классификации

### 2.2.1. Гипотеза о важности S.M.A.R.T. параметров при классификации отказа диска

Следующие S.M.A.R.T. параметры считаются критически важными для прогнозирования отказа дисков<sup>3</sup>

- Количество перераспределенных секторов (*Reallocated sectors count*)
- Сквозная ошибка (*End-to-end error*)
- Сообщения о неисправимых ошибках (*Reported Uncorrectable Errors*)
- Текущее количество ожидающих секторов (*Current Pending Sector Count*)
- Количество неисправимых секторов (*Uncorrectable Sector Count*)

Исходя из того, что эти параметры считаются критическими, использование только их для обучения может улучшить характеристики модели. Справедливость данного предположения проверялась с помощью нескольких методов: метода опорных векторов, метода  $K$  ближай-

---

<sup>2</sup><https://www.kaggle.com/datasets/awant08/hard-drive-failure-prediction-st4000dm000> Дата последнего обращения 27.12.2022

<sup>3</sup>[https://en.wikipedia.org/wiki/Self-Monitoring,\\_Analysis\\_and\\_Reporting\\_Technology](https://en.wikipedia.org/wiki/Self-Monitoring,_Analysis_and_Reporting_Technology) Дата последнего обращения 27.12.2022

ших соседей, метода случайного леса. Результаты работы методов измерялись с помощью метрик  $FAR$  — частоты ложных положительных классификаций и  $FDR$  (*Failure Detection Rate*) — отношения выявленных отказавших дисков к общему числу отказавших дисков.

### 2.2.2. Применение метода опорных векторов

Так как рассмотренный в разделе 1.1.2 метод опорных векторов одним из первых применялся к прогнозированию отказа жестких дисков, было принято решение оценить применимость этого метода к прогнозированию отказов жестких дисков модели SEAGATE ST4000DM000. Данный метод подтвердил свою низкую производительность в прогнозировании отказа жестких дисков и на 17 выделенных признаках за время, значительно превосходящее время обучения других моделей, не удалось обучить модель с использованием метода опорных векторов.

В результате применения данного метода к данным модели SEAGATE ST4000DM000 на 5 признаках, соответствующих критическим параметрам S.M.A.R.T., были достигнуты следующие метрики:

- $FDR = 1 - \frac{2812}{(2812 + 395)} = 0.123$
- $FAR = \frac{67}{95020} = 0.0007$

### 2.2.3. Применение метода $K$ ближайших соседей

Метод  $K$  ближайших соседей был выбран ввиду того, что показал наибольшую точность 0.974% при 0.003% ложных положительных классификаций [22][19], а также не требовал предварительной подготовки для его использования, облегчая процесс проверки гипотезы.

В результате применения данного метода к данным модели SEAGATE ST4000DM000 на 17 выделенных признаках были достигнуты следующие метрики:

- $FDR = 1 - \frac{740}{(740 + 2467)} = 0.769$

- $FAR = \frac{411}{95020} = 0.004$

В результате применения данного метода к данным модели SEAGATE ST4000DM000 на 5 признаках, соответствующих критическим S.M.A.R.T., были достигнуты следующие метрики:

- $FDR = 1 - \frac{2817}{(2817 + 390)} = 0.122$

- $FAR = \frac{64}{95020} = 0.0006$

#### 2.2.4. Применение метода случайного леса

Метод случайного леса был выбран потому, что показал один из лучших результатов [22][19], классифицировав 0.943% отказов жестких дисков при 0.004 ложных положительных классификаций,

В результате применения данного метода к данным модели SEAGATE ST4000DM000 на 17 выделенных признаках были достигнуты следующие метрики:

- $FDR = 1 - \frac{586}{(586 + 2621)} = 1 - 0.183 = 0.817$

- $FAR = \frac{212}{95020} = 0.002$

В результате применения данного метода к данным модели SEAGATE ST4000DM000 на 5 признаках, соответствующих критическим S.M.A.R.T., были достигнуты следующие метрики:

- $FDR = 1 - \frac{2808}{(2808 + 399)} = 0.124$

- $FAR = \frac{67}{95020} = 0.0007$

Использование при обучении только признаков, соответствующих S.M.A.R.T. параметрам, считающимся критическими, значительно увеличило количество ложных отрицательных классификаций, таким образом ухудшив характеристики модели. Таким образом, предположение о том, что использование только признаков, соответствующих критическим S.M.A.R.T. параметрам, улучшит показатели моделей, было

опровергнуто, и в дальнейшем при обучении предполагается использовать остальные S.M.A.R.T. параметры.

## 2.3. Применение алгоритмов выявления аномалий

Для оценки работы алгоритмов выявления аномалий используются те же метрики, что и для оценки работы алгоритмов бинарной классификации, а именно  $FAR$  — частота ложных положительных классификаций и  $FDR$  (*Failure Detection Rate*) — отношение выявленных отказавших дисков к общему числу отказавших дисков.

### 2.3.1. Isolation Forest

Алгоритм изолированного леса применялся в соответствии с проведенным исследованием о прогнозировании отказа дисков [23]. Было создано две модели, использующие алгоритм изолированного леса со значениями параметра *contamination* (равному доле наблюдений в наборе данных, которые следует идентифицировать как аномальные) равными 0.01 и 0.0002. В результате применения алгоритма изолированного леса со значением параметра *contamination* = 0.01 к данным были достигнуты следующие значения метрик:

- $FAR = \frac{886}{121910 + 886} = 0.0072$
- $FDR = 1 - \frac{3654}{4162 + 2} = 0.1225$

В результате применения алгоритма изолированного леса с *contamination* = 0.0002 к данным были достигнуты следующие значения метрик:

- $FDR = 1 - \frac{4162}{4162 + 2} = 0.0004$
- $FAR = \frac{35}{121910 + 35} = 0.0002$

Таким образом, применение изолированного леса со значением параметра *contamination* = 0.01 позволило достичь более низкой частоты ложных классификаций ( $FAR$ ) при более высокой частоте детекции

отказавших дисков ( $FDR$ ) по сравнению с результатами применения метода случайного леса, изложенными в 2. Дальнейшее повышение параметра *contamination* позволит достичь большего значения частоты классификации отказавших дисков.

### 2.3.2. Расстояние Махаланобиса

Алгоритм выявления аномалий с помощью расстояния Махаланобиса был реализован в соответствии с исследованием [18] [31]. В результате выявления аномалий с помощью расстояния Махаланобиса были достигнуты следующие метрики:

- $FDR = 1 - \frac{3970}{3970 + 194} = 0.0466$
- $FAR = \frac{712}{122084 + 712} = 0.0058$

Так как алгоритм использует 4 оценщика, зависящих от заданных параметров, в процессе своей работы, результаты работы алгоритма зависят как от набора данных, так и от того, насколько оптимально подобраны заданные параметры. Потенциально текущие результаты могут быть улучшены, так как подбор оптимальных параметров оценщиков не проводился.

## 2.4. Применение алгоритмов кластеризации

### 2.4.1. Применение метода главных компонент для сокращения размерности набора данных

Работа алгоритмов кластеризации требует много ресурсов, поэтому применение их напрямую к набору данных жестких дисков, содержащему множество признаков, может занять очень большое количество времени. Так как рассматриваемый набор данных жестких дисков даже после очистки содержит большое количество признаков, для применения алгоритмов кластеризации было полезно сократить размерность данных. Для этого использовался метод главных компонент [26], являющийся одним из наиболее распространенных методов для снижения

Таблица 1: PCA on open data

Размерность данных	Количество информации
4	80%
7	95%

размерности данных. Результаты применения метода главных компонент, представленные в таблице 1 показали, что снижение размерности данных до 4 позволит сохранить 80% информации о наборе данных дисков, снижение размерности данных до 7 позволит сохранить 95% информации соответственно.

К набору данных сниженной размерности было применено несколько алгоритмов кластеризации, описанных в 1. Для сравнения алгоритмов кластеризации используются метрики, отличные от метрик, использующихся для оценки решений задачи классификации. Так как набор данных обладает разметкой, для повышения точности измерения работы различных алгоритмов кластеризации использовались метрики, учитывающие наличие разметки: скорректированный индекс Рэнда (ARI) [10], скорректированная взаимная информация (AMI) [30], индекс Фаулкса-Мэллоуза (FMI) [6].

**Определение 2.4.1** *Скорректированный индекс Рэнда (ARI) — метрика, отражающая меру подобия между двумя кластерами. Пусть  $C$  — кластеризация, заданная разметкой,  $K$  — кластеризация, полученная с помощью алгоритма,  $a$  — количество пар элементов, которые попали в один кластер кластеризации  $C$  и в один кластер кластеризации  $K$ ,  $b$  — количество пар элементов, которые попали в разные кластера кластеризации  $C$  и в разные кластера кластеризации  $K$ . Тогда скорректированный индекс Рэнда может быть выражен следующей формулой:*

$$ARI = \frac{RI - \mathbb{E}[RI]}{\max(RI) - \mathbb{E}[RI]} \quad (4)$$

$RI$  есть нескорректированный индекс Рэнда, который выражается следующим образом:

$$RI = \frac{a + b}{C_2^{n_{samples}}} \quad (5)$$

где  $C_2^{n_{samples}}$  — число всевозможных пар в рассматриваемом наборе данных.

**Определение 2.4.2** Пусть  $U, V$  есть две разметки на  $N$  объектах. Их энтропия  $H(U), H(V)$  определяется следующим образом:

$$H(U) = - \sum_{i=1}^{|U|} P(i) * \log P(i) \quad (6)$$

$$H(V) = - \sum_{j=1}^{|V|} \hat{P}(j) * \log \hat{P}(j) \quad (7)$$

Где  $P(i) = U_i/N$  и  $\hat{P}(j) = |V_j|/N$ . Их взаимная информация может быть выражена следующей формулой:

$$MI(U, V) = \sum_{i=1}^{|U|} \sum_{j=1}^{|V|} \frac{|U_i \cap V_j|}{N} \log \left( \frac{N|U_i \cap V_j|}{|U_i||V_j|} \right) \quad (8)$$

и математическое ожидание взаимной информации может быть выражено следующим образом:

$$\begin{aligned} \mathbb{E}[MI] = & \sum_{i=1}^{|U|} \sum_{j=1}^{|V|} \sum_{n_{ij}=(a_i+b_j-N)^+}^{\min(a_i, b_j)} \frac{n_{ij}}{N} \log \left( \frac{N n_{ij}}{a_i b_j} \right) * \\ & * \frac{a_i! b_j! (N - a_i)! (N - b_j)!}{N! n_{ij}! (a_i - n_{ij})! (b_j - n_{ij})! (N - a_i - b_j + n_{ij})!} \end{aligned} \quad (9)$$

где  $a_i = |U_i|$  и  $b_j = |V_j|$  (число элементов в  $U_i$  и в  $V_j$  соответственно) и  $(a_i + b_j - N)^+$  есть  $\max(0, a_i + b_j - N)$ . Тогда скорректированная взаимная информация может быть выражена следующим образом:

$$AMI = \frac{MI - \mathbb{E}[MI]}{\text{mean}(H(U), H(V)) - \mathbb{E}[MI]} \quad (10)$$

**Определение 2.4.3** Индекс Фаулкса-Мэллоуза определяется как среднее геометрическое точности и полноты и определяется следующим образом:

$$FMI = \frac{TP}{\sqrt{(TP + FP)(TP + FN)}} \quad (11)$$



где  $TP$  (*True Positive*) — число пар точек, которые принадлежат к одним и тем же кластерам для обеих кластеризаций,  $FP$  (*False Positive*) — число пар точек, которые принадлежат к одним и тем же кластерам для кластеризации, задаваемой разметкой, и принадлежат к разным кластерам для предсказанной кластеризации,  $FN$  (*False Negative*) — число пар точек, которые принадлежат к разным кластерам для кластеризации, задаваемой разметки и к одному кластеру в случае предсказанной кластеризации.

#### 2.4.2. Сравнительный анализ алгоритмов кластеризации

Результаты применения алгоритмов кластеризации *KMeans*, *Bisecting KMeans*, *Spectral Clustering*, *Mean Shift*, *OPTICS* на наборе данных сниженных размерностей 4 и 7 представлены в таблице 2.

Таблица 2: HDD failure prediction using clustering methods

Алгоритм	Размерность данных	Время обучения, сек	ARI	AMI	FMI
KMeans	4	1.712	0.001	0.002	0.686
KMeans	7	1.802	0.001	0.002	0.686
OPTICS	4	3170.495	0.0	0.011	0.310
OPTICS	7	4749.342	0.0	0.008	0.305
MeanShift	4	12067.558	0.0	0.0	0.970
MeanShift	7	21211.853	0.003	0.004	0.962
SpectralClustering	4	32619.471	0.005	0.003	0.005
SpectralClustering	7	25367.726	0.005	0.001	0.936

Для измерения качества кластеризации использованы приведенные в 2.4.1 2.4.2 2.4.3 метрики  $ARI$ ,  $AMI$ ,  $FMI$ . В результате анализа таблицы можно сделать вывод, что проведение кластеризации для рассматриваемого набора данных показало плохие результаты для всех алгоритмов — так, например, максимальное значение  $ARI$  не превышает 0.005, что свидетельствует о том, что метки кластеров расставлены на данных почти случайным образом. Это демонстрирует то, что из рассмотренных данных жестких дисков не удалось выделить некоторые общие модели поведения жестких дисков.

## 2.5. Анализ примененных подходов

В исследовании были рассмотрены три подхода к прогнозированию отказа жестких дисков: прогнозирование отказа жесткого диска с помощью решения задачи бинарной классификации, с помощью решения задачи выявления аномалий, прогнозирование с помощью кластеризации. Недостатком примененных подходов, основывающихся на решении задачи бинарной классификации, является необходимость разметки набора данных, которую трудно получить для реальных данных жестких дисков, собранных с корпоративных систем. Подходы к прогнозированию, основывающиеся на выявлении аномалий, не требуют разметки. В исследовании они показали более низкие доли детекции отказавших дисков по сравнению с алгоритмами бинарной классификации. Доли ложных классификаций у этих алгоритмов также значительно ниже алгоритмов бинарной классификации, поэтому эти алгоритмы потенциально позволят классифицировать большее количество отказавших дисков при соответствующем повышении частот ложных классификаций. Также для прогнозирования отказа жестких дисков были применены различные алгоритмы кластеризации. Применение алгоритмов кластеризации показало низкие результаты, что может говорить либо о недостаточности данных, либо о том, что для рассматриваемого набора данных нельзя выделить несколько явных моделей поведения, на которые в дальнейшем можно было бы кластеризовать диски. Таким образом, для рассматриваемого набора данных с точки зрения применимости на реальных системах наиболее перспективным оказался подход прогнозирования отказа дисков с помощью выявления аномалий.

### **3. Применение подходов на реальных данных**

С ростом продаж системы хранения данных TATLIN.UNIFIED компании YADRO выросло количество обращений пользователей этих систем о замене жесткого диска, сбоящего в той или иной системе. Каждое такое обращение требует времени на верификацию состояния диска инженером поддержки с последующей его заменой в случае, если диск действительно отказал. Зачастую точно установить факт отказа диска нельзя — тогда во избежание возможного его отказа, потенциально приводящего к потере данных, этот диск в системе хранения все равно заменяется. Замененный диск не может быть использован в дальнейшем для каких-либо других целей, так как потенциально содержит конфиденциальные пользовательские данные — поэтому такие диски утилизируют, приводя их в полностью неработоспособное состояние. Возросшее количество случаев замены дисков в системах хранения данных TATLIN.UNIFIED привело к увеличению расходов компании на диагностику таких дисков и закупку новых, поэтому задача автоматизации и улучшения анализа дисков с целью уменьшения ложноположительных классификаций дисков как отказавших стала приоритетной.

#### **3.1. Формирование набора данных**

Для сбора информации, необходимой для анализа подозрительных дисков, в компании было доступно два источника данных — система отслеживания инцидентов NAUMEN, а также система сбора отчетов о состоянии систем хранения данных SYR, содержащая, в частности, отчеты о состояниях дисков. Для проведения дальнейшего анализа надлежит рассмотреть данные, предоставляемые каждой из этих систем, отдельно.

### 3.1.1. Набор данных NAUMEN

В системе отслеживания инцидентов NAUMEN на каждый подозрительный диск заводится инцидент, за обработку которого в дальнейшем ответственен инженер поддержки — он верифицирует состояние диска, запуская различные диагностические команды. В частности, обязательным этапом анализа диска является вызов команды для сбора S.M.A.R.T. параметров диска и последующий их анализ. Например, для диска */dev/sda* команда вызова выглядит следующим образом.

$$smartctl -a /dev/sda$$

Эта команда позволяет собрать набор S.M.A.R.T. параметров для SAS дисков, представленный в таблице 3. Набор параметров, предоставляемых SAS диском, отличается от набора параметров, предоставляемых SATA диском, на которых проводились все доступные на текущий момент исследования, поэтому для анализа дисков в дальнейшем будут рассматриваться все параметры S.M.A.R.T..

Таблица 3: Доступные S.M.A.R.T. параметры

<i>Название S.M.A.R.T. параметра</i>
Current Drive Temperature
Drive Trip Temperature
Manufactured in week
Specified cycle count over device lifetime
Accumulated start-stop cycles
Specified load-unload count over device lifetime
Accumulated load-unload cycles
Read/Write/Verify errors corrected by ECC fast/delayed
Read/Write/Verify errors corrected by rereads/rewrites
Read/Write/Verify total errors corrected
Read/Write/Verify correction algorithm invocations
Read/Write/Verify total uncorrected errors

Результаты выполнения диагностических команд прикладываются

в качестве комментария к инциденту в системе отслеживания инцидентов NAUMEN. Таким образом, данные параметров S.M.A.R.T. о диске в NAUMEN хранятся в необработанных текстах комментариев и требуют синтаксического анализа для формирования сопоставления диску его параметров в момент заведения инцидента.

Также в одном инциденте может быть упомянуто сразу несколько дисков — в этом случае для каждого из этих дисков требуется выделить соответствующие ему S.M.A.R.T. параметры, содержащиеся в комментариях.

Признаки данных NAUMEN, необходимые для дальнейшего анализа диска, и примеры их значений, приведены в таблице 4. Остальные признаки данных NAUMEN не приведены и не участвуют в анализе диска.

Таблица 4: Пример наблюдения в наборе данных NAUMEN

Номер инцидента	Время создания инцидента	Номер комментария в инциденте	Идентификатор диска	S.M.A.R.T. параметры диска ...
INC511868	17.07.2021 07:03	comment26501144	9RHNP3DC	...

В таблице 4 колонка "Номер инцидента" соответствует колонке с номером инцидента в собранном наборе данных, колонка "Время создания инцидента" содержит время, в которое был заведен инцидент в системе NAUMEN, колонка "Номер комментария в инциденте" содержит номер комментария в указанном инциденте, из которого выделены S.M.A.R.T. параметры диска в рассматриваемом наблюдении. Колонка "Идентификатор диска" содержит идентификатор диска в системе — его серийный номер. Колонка "S.M.A.R.T. параметры диска" соответствует набору колонок, содержащих значения S.M.A.R.T. параметров в собранном наборе данных NAUMEN.

### 3.1.2. Набор данных SYR

Система сбора отчетов о состоянии систем хранения данных SYR собирает отчеты о состоянии каждой компоненты системы — в частности, дисков. Один отчет о состоянии системы хранения данных SYR

содержит в себе все диски системы. Состояние диска определяется технологией TRAIID — на основании этой технологии диск может принимать несколько состояний: OK (диск функционирует нормально), REPLACED (диск отказал и был успешно выведен из процесса функционирования системы), RECOVERING (диск отказал и в текущий момент производится работа по выключению диска из процесса функционирования системы) и другие. В отчете о состоянии диска содержится только время отчета и состояние диска, при этом период сбора отчетов достаточно велик. Это объясняется тем, что проведение регулярного опрашивания систем, находящихся в эксплуатации у пользователей, с целью сбора отчетов о состоянии, подвергает их дополнительной нагрузке, которая может значительно влиять на работоспособность.

Признаки данных SYR, необходимые для дальнейшего анализа диска, и примеры их значений, приведены в таблице 5. Остальные признаки данных SYR не приведены и не участвуют в анализе диска.

Таблица 5: Пример наблюдения в наборе данных SYR

Дата отчета	Идентификатор диска	Состояние диска в момент отчета
17.07.2021 07:03	9RHP142L	OK

Колонка "Дата отчета" соответствует дате собранного отчета о состоянии системы хранения данных (ее дисков), колонка "идентификатор диска" содержит идентификатор диска — его серийный номер, колонка "состояние диска в момент отчета" содержит соответствующее состояние диска: OK, REPLACED и другие.

### 3.1.3. Слияние данных NAUMEN и SYR

Из рассмотренных данных NAUMEN и SYR можно сформировать единый набор наблюдений, состоящий из снимка S.M.A.R.T. параметров, приведенных в NAUMEN и состояния диска (разметки), взятого из SYR. Состояние диска из системы SYR сопоставляется совокупности S.M.A.R.T. параметров диска из NAUMEN по серийному номеру диска. Для снимка S.M.A.R.T. параметров из NAUMEN берется ближайший по

времени, следующем за датой создания инцидента отчет о состоянии системы — состояние диска в таком отчете отображает результат обработки инцидента (например, REPLACED в случае замены диска, ОК в случае отметки диска как корректно функционирующего и т.д.).

Таким образом, сформированный набор данных представляет собой снимок S.M.A.R.T. параметров диска и его состояния. Такие данные предоставляют возможность для применения алгоритмов классификации и кластеризации к анализу отказа дисков, так как признак состояния диска может рассматриваться в качестве разметки. Получившиеся данные имеют 27 признаков и состоят из 284 различных наблюдений.

## **3.2. Кластеризация сформированного набора данных**

Так как сформированный на основе данных NAUMEN и SYR набор не содержит временных рядов, задачу предсказания отказа диска на лету с прогнозированием примерного времени отказа не представляется возможным. Наличие разметки на данных позволяет автоматизировать диагностику состояния диска путем кластеризации, которая позволит разбить имеющиеся диски на кластеры и, возможно, выявить какие-то закономерности поведения в дисках.

Кластеризация данных проводилась с помощью применения алгоритмов кластеризации, примененных на модельных данных в главе 2, а также с помощью визуализации данных — путем проектирования данных на двумерное пространство посредством применения t-SNE [33].

### **3.2.1. Визуализация данных с помощью проекции**

Визуализация данных t-SNE позволила выделить в данных кластер, состоящий из 56 дисков. Результаты визуализации представлены на графике 1. Данные спроектированы на трехмерное пространство, где каждое наблюдение соответствует точке в двумерной системе координат и окрашено определенным цветом. Цвет наблюдения диска определяется состоянием диска — соответственно, скопления точек одного цвета на графике отмечают наличие кластера схожих дисков, имею-

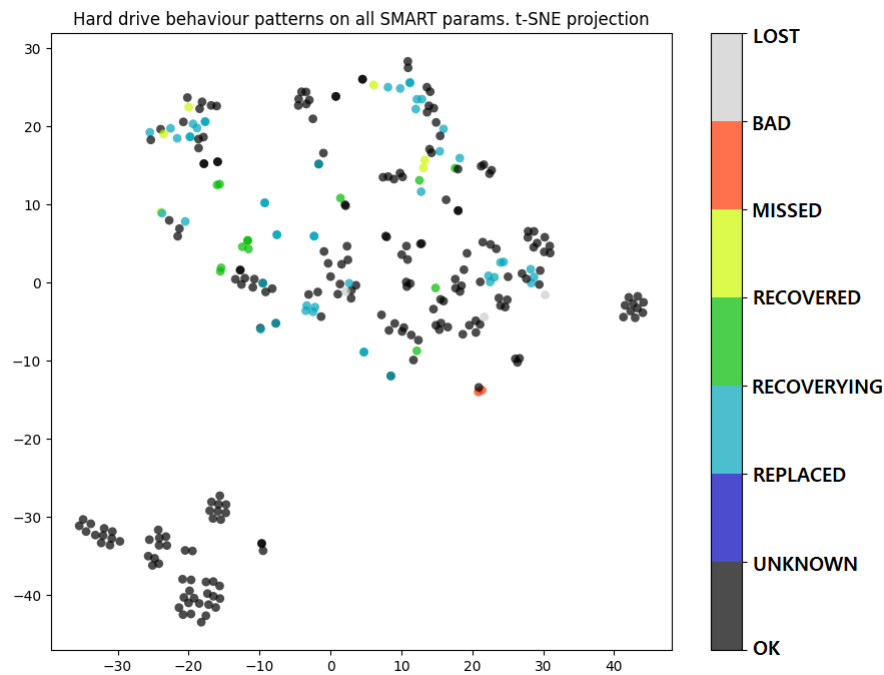


Рис. 1: Визуализация данных с помощью t-SNE

щих одно и то же состояние (например, ОК). Диск может принимать 8 различных состояний, цвета, соответствующие каждому из состояний, представлены справа от графика.

На представленном графике 1 можно выделить кластер дисков с состоянием ОК, расположенный в левом нижнем углу графика — это скопление дисков отделено от остальных данных, поэтому кажется важным исследовать диски в кластере на предмет каких-либо паттернов, отличающих их от остальных. О расположении проекций данных остальных дисков, расположенных в верхней части графика, невозможно что-либо заключить, так как соответствующие точки дисков расположены на близком расстоянии друг от друга, диски имеют разные состояния, и поэтому не могут быть объединены в какие-либо кластеры.

### 3.2.2. Применение алгоритмов кластеризации

Также для оценки кластеризуемости сформированных данных были применены различные алгоритмы кластеризации, ранее примененные на модельных данных в главе 2. Перед запуском алгоритмов кластеризации был применен метод главных компонент для снижения размерно-



Таблица 6: PCA on real data

Размерность данных	Количество информации
3	39%
7	80%

сти, результаты которого приведены в таблице 6. Из таблицы 6 следует, что для сохранения 80% информации о данных требуется 7 параметров. На модельных данных с использованием 7 параметров можно было сохранить 95% информации, что говорит о меньшей избыточности признаков в реальных данных. Результаты применения алгоритмов кластеризации представлены в таблице 7. Можно отметить, что метрики качества кластеризации значительно выше, чем метрики, полученные на открытых данных 2.

Таблица 7: HDD failure prediction using clustering methods

Algorithm	Data dimension	Learning time, sec	ARI	AMI	FMI
KMeans	27	0.009	0.065	0.113	0.606
KMeans	7	0.009	0.064	0.118	0.584
KMeans	3	0.008	0.033	0.127	0.562
BisectingKMeans	27	0.029	0.056	0.096	0.581
BisectingKMeans	7	0.013	0.063	0.099	0.581
BisectingKMeans	3	0.011	0.045	0.079	0.580
MeanShift	27	0.545	0.085	0.076	0.706
MeanShift	7	0.884	0.199	0.150	0.713
MeanShift	3	0.405	0.133	0.047	0.714
Spectral Clustering	27	0.184	0.198	0.140	0.770
Spectral Clustering	7	0.265	0.215	0.133	0.767
Spectral Clustering	3	0.116	0.200	0.127	0.767
Agglomerative Clustering	27	0.006	0.122	0.126	0.763
Agglomerative Clustering	7	0.006	0.160	0.119	0.767
Agglomerative Clustering	3	0.005	0.119	0.110	0.763

Показатели *ARI* и *AMI* достигают значений 0.21 и 0.15 и достаточно далеки от значения 1, соответствующего идеальной кластеризации — это означает, что данные кластеризуются не очень хорошо. Такие результаты согласуются с результатами, полученными с помощью визуализации — применение проектирования данных с помощью t-SNE позволило визуализировать небольшой кластер из корректно функционирующих дисков и показало, что большинство данных нельзя разбить на кластеры. Кажется возможным улучшение результатов с увеличением размеров данных — так как на момент исследования удалось сформировать данные, состоящие только из 284 наблюдений, потенциально с увеличением наблюдений удастся сформировать новые кластера поведения дисков.

### 3.3. Анализ выявленного кластера

С помощью t-SNE удалось выявить кластер из 56 дисков, о которых были заведены инциденты в NAUMEN и которые в результате диагностики оказались корректно функционирующими (имели состояние ОК в соответствующем отчете о состоянии из SYR). Наличие специфических характеристик поведения дисков в найденном кластере позволит проверять дальнейшие диски в инцидентах системы NAUMEN на принадлежность этому кластеру и, соответственно, автоматизирует подтверждение корректности функционирования диска. Диски, у которых имеются те же характеристики, что и у дисков кластера, скорее всего принадлежат к этому кластеру, а значит, корректно функционируют. Для выявления таких специфических характеристик в этом кластере необходимо его проанализировать.

Чтобы выявить специфические характеристики кластера, были рассмотрены значения каждого из 27 признаков набора данных, содержащих значения S.M.A.R.T. параметров, на данных внутри кластера и вне его. При таком рассмотрении признаков были найдены следующие характерные поведения дисков в кластере:

- Значение параметра *"Gigabytes processed 10<sup>9</sup> bytes verify"* при-

нимает значение 0 для всех дисков вне кластера, а для дисков в кластере принимает значение от 0 до 14 (что может свидетельствовать о том, что на всех дисках в кластере запускались проверки).

- Диски в кластере имеют значение *Drive Trip Temperature* = 60C, вне кластера диски принимают значение *Drive Trip Temperature* = 85C.
- Все диски, принадлежащие кластеру, содержат дополнительную секцию *Vendor (Seagate/Hitachi) factory information*. Диски в кластере это почти все такие диски, имеющиеся в наборе данных — из остальных 228 дисков всего 9 также содержат S.M.A.R.T. секцию *Vendor (Seagate/Hitachi) factory information*.
- Все диски в кластере имеют значение *Compliance* = *SPC* − 5. Почти все диски вне кластера имеют значение *Compliance* = *SPC* − 4: значение *Compliance* = *SPC* − 5 имеют только 16 дисков.

Таким образом, можно предположить, что наличие S.M.A.R.T. секции *Vendor (Seagate/Hitachi) factory information* секции определяется реализацией диска в соответствии с *SCSI Primary Commands* 5<sup>4</sup> — на данный момент почти все инциденты про такие диски в системе инцидентов NAUMEN являлись ложно положительными. Поэтому можно рекомендовать при анализе состояния диска с помощью S.M.A.R.T. параметров проверять, что значение *Compliance* = *SPC* − 5 и в результате выполнения команды сбора S.M.A.R.T. параметров имеется секция *Vendor (Seagate/Hitachi) factory information* — в случае, если эти условия выполняются, есть основания утверждать, что диск функционирует корректно, так как принадлежит к найденному кластеру корректно функционирующих дисков.

---

<sup>4</sup>[https://standards.incits.org/apps/group\\_public/download.php/109877/eb-2019-00306-Public-Review-Register-INCITS-502-201x-Comments-Due-08-19-2019.pdf](https://standards.incits.org/apps/group_public/download.php/109877/eb-2019-00306-Public-Review-Register-INCITS-502-201x-Comments-Due-08-19-2019.pdf)  
последнего обращения 25.12.2023

# Заключение

В ходе производственной практики были выполнены следующие задачи:

- Проведен обзор предметной области и рассмотрены алгоритмы, реализующие такие подходы машинного обучения для прогнозирования отказа жесткого диска как:
  - Прогнозирование отказа жесткого диска с помощью решения задачи бинарной классификации;
  - Прогнозирование отказа жесткого диска с помощью решения задачи выявления аномалий;
  - Прогнозирование отказа жесткого диска с помощью кластеризации.
- Для анализа модельного набора данных применены следующие методы, рассмотренные в обзорной части работы:
  - Метод опорных векторов, случайного леса и  $K$  ближайших соседей в рамках решения задачи бинарной классификации;
  - Метод изолированного леса, выявления аномалий с использованием расстояния Махаланобиса в рамках решения задачи выявления аномалий;
  - Методы *KMeans*, *Bisecting KMeans*, *Spectral Clustering*, *Mean Shift*, *OPTICS* в рамках решения задачи кластеризации.
- На основе нескольких источников реальных данных был сформирован набор данных для диагностики отказа диска по его снимку S.M.A.R.T. параметров.
- Для выявления паттернов в сформированном наборе реальных данных были применены различные алгоритмы кластеризации: *KMeans*, *Bisecting KMeans*, *Spectral Clustering*, *Mean Shift*, *Agglomerative Clustering*, а также подход визуализации кластеров с помощью проектирования данных на двумерное пространство t-SNE.

- Найденный с помощью T-SNE кластер был проанализирован, сформированы характеристики дисков, принадлежащих этому кластеру: наличие признака *Compliance* со значением *SPC* – 5, признака *Drive Trip Temperature* со значением *60C*, а также секции *Vendor (Seagate/Hitachi) factory information*.
- На основании найденных характеристик сформулирована рекомендация все диагностируемые диски, имеющие перечисленные характеристики, считать корректно функционирующими.
- На основании анализа реальных данных можно рекомендовать применение подходов кластеризации, а именно алгоритмы агломеративной, спектральной кластеризации и визуализацию кластеров с помощью T-SNE как наиболее перспективные в анализе отказа дисков. Эти подходы не требуют наличия временных рядов S.M.A.R.T. параметров дисков. Алгоритмы кластеризации используют один снимок S.M.A.R.T. параметров, чтобы выявить паттерны поведения в данных и позволяют на их основе автоматизировать процесс определения текущего состояния конкретного диска.

В рамках продолжения исследований планируется выполнить следующие задачи:

- Улучшить кластеризуемость данных: выявить различные паттерны поведения в дисках, не попавших в кластер.
- На основе отобранных подходов кластеризации сформировать систему, которая автоматизирует определение текущего состояния диска в системе TATLIN.UNIFIED и интегрировать ее в текущий процесс обработки инцидентов дисков.

## Список литературы

- [1] Jiang Weihang, Hu Chongfeng, Zhou Yuanyuan, and Kanevsky Arkady. Are Disks the Dominant Contributor for Storage Failures? A Comprehensive Study of Storage Subsystem Failure Characteristics // [ACM Trans. Storage](#). — 2008. — nov. — Vol. 4, no. 3. — Access mode: <https://doi.org/10.1145/1416944.1416946>.
- [2] Baum Leonard E. and Petrie Ted. Statistical Inference for Probabilistic Functions of Finite State Markov Chains // [Annals of Mathematical Statistics](#). — 1966. — Vol. 37. — P. 1554–1563.
- [3] Breiman L. Random Forests // [Machine Learning](#). — 2001. — 10. — Vol. 45. — P. 5–32.
- [4] Di Jian and Gou Xinyu. Bisecting K-means Algorithm Based on K-valued Selfdetermining and Clustering Center Optimization // [J. Comput.](#) — 2018. — Vol. 13. — P. 588–595.
- [5] Fix Evelyn and Hodges Joseph L. Discriminatory Analysis - Nonparametric Discrimination: Consistency Properties // [International Statistical Review](#). — 1989. — Vol. 57. — P. 238.
- [6] Fowlkes E. B. and Mallows C. L. A Method for Comparing Two Hierarchical Clusterings // [Journal of the American Statistical Association](#). — 1983. — Vol. 78, no. 383. — P. 553–569. — <https://www.tandfonline.com/doi/pdf/10.1080/01621459.1983.10478008>.
- [7] Hamerly Greg and Elkan Charles. Bayesian Approaches to Failure Prediction for Disk Drives // [Proceedings of the Eighteenth International Conference on Machine Learning](#). — San Francisco, CA, USA : Morgan Kaufmann Publishers Inc. — 2001. — ICML '01. — P. 202–209.
- [8] Tomer Vikas, Sharma Vedna, Gupta Sonali, and Singh Devesh. Hard disk drive failure prediction using SMART attribute // [Materials Today: Proceedings](#). — 2021. — 04. — Vol. 46.

- [9] Hilbert Martin and López Priscila. The World's Technological Capacity to Store, Communicate, and Compute Information // [Science \(New York, N.Y.\)](#). — 2011. — 02. — Vol. 332. — P. 60–5.
- [10] Hubert Lawrence and Arabie Phipps. Comparing partitions // [Journal of Classification](#). — 1985. — Dec. — Vol. 2, no. 1. — P. 193–218. — Access mode: <https://doi.org/10.1007/BF01908075>.
- [11] Hughes Gordon, Murray Joseph, Kreutz-Delgado Ken, and Elkan Charles. Improved disk-drive failure warnings // [Reliability, IEEE Transactions on](#). — 2002. — 10. — Vol. 51. — P. 350 – 357.
- [12] Liu Fei Tony, Ting Kai Ming, and Zhou Zhi-Hua. [Isolation Forest](#) // 2008 Eighth IEEE International Conference on Data Mining. — 2008. — P. 413–422.
- [13] Lloyd Stuart P. Least squares quantization in PCM // [IEEE Trans. Inf. Theory](#). — 1982. — Vol. 28. — P. 129–136.
- [14] Morales-Forero A. and Bassetto S. [Case Study: A Semi-Supervised Methodology for Anomaly Detection and Diagnosis](#) // 2019 IEEE International Conference on Industrial Engineering and Engineering Management (IEEM). — 2019. — P. 1031–1037.
- [15] Murray Joseph, Hughes Gordon, and Kreutz-Delgado Ken. Hard drive failure prediction using non-parametric statistical methods. — 2003. — 01.
- [16] Murray Joseph F., Hughes Gordon F., and Kreutz-Delgado Kenneth. Machine Learning Methods for Predicting Failures in Hard Drives: A Multiple-Instance Application // [J. Mach. Learn. Res.](#) — 2005. — dec. — Vol. 6. — P. 783–816.
- [17] Ankerst Mihael, Breunig Markus M., Kriegel Hans-Peter, and Sander Jörg. [OPTICS: Ordering Points to Identify the Clustering Structure](#) // Proceedings of the 1999 ACM SIGMOD International

Conference on Management of Data. — New York, NY, USA : Association for Computing Machinery. — 1999. — SIGMOD '99. — P. 49–60. — Access mode: <https://doi.org/10.1145/304182.304187>.

- [18] Wang Yu, Miao Qiang, Ma Eden W. M., Tsui Kwok-Leung, and Pecht Michael G. Online Anomaly Detection for Hard Disk Drives Based on Mahalanobis Distance // [IEEE Transactions on Reliability](#). — 2013. — Vol. 62, no. 1. — P. 136–145.
- [19] Pitakrat Teerat, van Hoorn André, and Grunske Lars. [A comparison of machine learning algorithms for proactive hard disk drive failure detection](#). — 2013. — 06. — P. 1–10.
- [20] Zhao Ying, Liu Xiang, Gan Siqing, and Zheng Weimin. [Predicting disk failures with HMM- and HSMM-based approaches](#). — 2010. — 07. — Vol. 6171. — P. 390–404.
- [21] Zhu Bingpeng, Wang Gang, Liu Xiaoguang, Hu Dianming, Lin Sheng, and Ma Jingwei. [Proactive drive failure prediction for large scale storage systems](#) // 2013 IEEE 29th Symposium on Mass Storage Systems and Technologies (MSST). — 2013. — P. 1–5.
- [22] Garcia Marco, Ivanov Vladimir, Kozar Anastasia, Litvinov Stanislav, Reznik Alexey, Romanov Vitaly, and Succi Giancarlo. Review of techniques for predicting hard drive failure with SMART attributes // [International Journal of Machine Intelligence and Sensory Signal Processing](#). — 2018. — 01. — Vol. 2. — P. 151.
- [23] Rombach Philipp and Keuper Janis. [SmartPred: Unsupervised Hard Disk Failure Detection](#) // High Performance Computing: ISC High Performance 2020 International Workshops, Frankfurt, Germany, June 21–25, 2020, Revised Selected Papers. — Berlin, Heidelberg : Springer-Verlag. — 2020. — P. 235–246. — Access mode: [https://doi.org/10.1007/978-3-030-59851-8\\_15](https://doi.org/10.1007/978-3-030-59851-8_15).
- [24] Sakurada Mayu and Yairi Takehisa. [Anomaly Detection Using Autoencoders with Nonlinear Dimensionality Reduction](#) // Proceedings



of the MLSDA 2014 2nd Workshop on Machine Learning for Sensory Data Analysis. — New York, NY, USA : Association for Computing Machinery. — 2014. — MLSDA'14. — P. 4–11. — Access mode: <https://doi.org/10.1145/2689746.2689747>.

- [25] Schroeder Bianca and Gibson Garth A. Disk Failures in the Real World: What Does an MTTF of 1,000,000 Hours Mean to You? // Proceedings of the 5th USENIX Conference on File and Storage Technologies. — USA : USENIX Association. — 2007. — FAST '07. — P. 1–es.
- [26] Shlens Jonathon. A Tutorial on Principal Component Analysis. — 2014. — 1404.1100.
- [27] Tan Yongmin and Gu Xiaohui. [On Predictability of System Anomalies in Real World](#) // 2010 IEEE International Symposium on Modeling, Analysis and Simulation of Computer and Telecommunication Systems. — 2010. — P. 133–140.
- [28] Pereira Francisco Lucas F., Castro Chaves Iago, Gomes João Paulo P., and Machado Javam C. [Using Autoencoders for Anomaly Detection in Hard Disk Drives](#) // 2020 International Joint Conference on Neural Networks (IJCNN). — 2020. — P. 1–7.
- [29] Vapnik Vladimir. [The Nature of Statistical Learning Theory](#). — 2000. — 01. — P. 69–91. — ISBN: [978-1-4419-3160-3](#).
- [30] Vinh Nguyen Xuan, Epps Julien, and Bailey James. [Information Theoretic Measures for Clusterings Comparison: Is a Correction for Chance Necessary?](#) // Proceedings of the 26th Annual International Conference on Machine Learning. — New York, NY, USA : Association for Computing Machinery. — 2009. — ICML '09. — P. 1073–1080. — Access mode: <https://doi.org/10.1145/1553374.1553511>.
- [31] Wang Yu, Miao Qiang, and Pecht Michael. [Health monitoring of hard disk drive based on Mahalanobis distance](#) // 2011 Prognostics and System Health Managment Confernece. — 2011. — P. 1–8.

- [32] Zhou Chong and Paffenroth Randy C. [Anomaly Detection with Robust Deep Autoencoders](#) // Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. — New York, NY, USA : Association for Computing Machinery. — 2017. — KDD '17. — P. 665–674. — Access mode: <https://doi.org/10.1145/3097983.3098052>.
- [33] van der Maaten Laurens and Hinton Geoffrey E. Visualizing Data using t-SNE // Journal of Machine Learning Research. — 2008. — Vol. 9. — P. 2579–2605. — Access mode: <https://api.semanticscholar.org/CorpusID:5855042>.
- [34] von Luxburg Ulrike. A Tutorial on Spectral Clustering. — 2007. — 0711.0189.