

Санкт-Петербургский государственный университет

Екатерина Петровна Винник

Отчет по производственной практике

Прогнозирование отказов жестких дисков системы Tatlin.Unified

Уровень образования: магистратура

Направление *02.04.03 «Математическое обеспечение и администрирование
информационных систем»*

Основная образовательная программа *ВМ.5666.2022 «Математическое обеспечение и
администрирование информационных систем»*

Профиль *Информационно-аналитические системы*

Научный руководитель:
к.ф.-м.н., В.И. Гориховский

Рецензент:
эксперт по разработке ПО ООО «Ядро Центр Программных Разработок» Д. А. Вольф

Санкт-Петербург
2024

Saint Petersburg State University

Ekaterina Vinnik

Pre-Diploma practice report

Failure Prediction in Tatlin.Unified Hard Disk Drives

Education level: master

Speciality *02.04.03 “Software and Administration of Information Systems”*

Programme *BM.5666.2022 “Software and Administration of Information Systems”*

Profile: *Software Engineering*

Scientific supervisor:
C.Sc. V. I. Gorikhovskii

Reviewer:
Software development expert at LLC «Yadro Software Development center» D. A. Volf

Saint Petersburg
2024

Оглавление

Введение	4
Постановка задачи	6
1. Существующие подходы к прогнозированию отказа жесткого диска	7
1.1. Прогнозирование отказа жесткого диска с помощью решения задачи бинарной классификации	7
1.2. Прогнозирование отказа жесткого диска с помощью решения задачи выявления аномалий	10
1.3. Прогнозирование отказа жесткого диска с помощью решения задачи кластеризации	13
2. Применение подходов на наборе модельных данных	18
2.1. Выбор набора модельных данных	18
2.2. Применение алгоритмов бинарной классификации	19
2.3. Применение алгоритмов выявления аномалий	22
2.4. Применение алгоритмов кластеризации	23
2.5. Анализ примененных подходов	27
3. Применение подходов на реальных данных	28
3.1. Формирование набора данных	28
3.2. Кластеризация сформированного набора данных	32
4. Построение оценки числа отказов дисков на 2025 год	41
Заключение	48
Список литературы	50

Введение

Жесткие диски являются распространенным устройством хранения и присутствуют в разных системах — от персональных компьютеров до систем хранения данных. Согласно [10], большинство информации, производимой в мире, хранится на жестких дисках. Частота отказов жесткого диска в год составляет чуть меньше 1% [26], что не удовлетворяет большое количество пользователей, так как в некоторых высоко масштабируемых системах, например, в центрах обработки данных или поставщиках интернет-услуг количество жестких дисков в одном вычислительном узле может легко достигать тысячи [1]. Отказ каждого из этих жестких дисков может не только увеличить время простоя сервиса, но и привести к потере данных.

Задача предсказания отказа жесткого диска является актуальной и для жестких дисков систем хранения данных компании *Yadro*, которая, согласно данным отчета корпорации *IDC* (*International Data Corporation*), является лидером российского рынка внешних систем хранения данных в емкостном выражении с долей 63.7%¹. С ростом продаж систем хранения данных *Tatlin.Archive*, *Tatlin.Unified* компании *Yadro* количество дисков, заменяемых в этих системах, возросло со 100 до более чем 1500 дисков за квартал. Замененные диски не могут быть переиспользованы компанией, так как потенциально хранят конфиденциальные пользовательские данные, поэтому каждый замененный диск утилизируется. Такой рост замен дисков повлек увеличение расходов компании *Yadro* на закупку новых дисков, а также стал требовать большего количества времени инженеров поддержки компании на диагностику дисков, подлежащих замене. Прогнозирование суммарного количества отказов дисков по всем системам хранения данных позволило бы оценить дальнейшие расходы компании на замену дисков и запланировать их закупку. Автоматизация определения состояния диска сократила бы время инженеров поддержки, а также снизила количество ложно положительных замен диска — то есть, излишних замен дисков,

¹<https://st.Yadro.com/docs/idc-whitepaper-rus.pdf> Дата последнего обращения 30.04.2024

которые в действительности работали корректно.

Существующая широко применяемая технология прогнозирования отказа жесткого диска *S.M.A.R.T.* (*self-monitoring, analysis and reporting technology*) заключается в отслеживании значений набора параметров на предмет превышения соответствующих пороговых значений. Хотя эта технология широко используется, частота предсказания отказов диска с ее помощью является достаточно низкой — ввиду стремления ее создателями снизить количество ложноположительных классификаций, технология *S.M.A.R.T.* позволяет предсказать от 3% до 10% отказов [16][17][12].

Для повышения частоты предсказания отказа дисков разрабатывались разные подходы, использующие в своей основе данные о поведении диска, собираемые с помощью технологии *S.M.A.R.T.*. Большинство этих подходов заключается в применении методов машинного обучения к данным, собираемым технологией *S.M.A.R.T.* [8][16][19][29][30]. Это связано с тем, что задача прогнозирования отказа диска является задачей бинарной классификации, которая в свою очередь является одной из самых распространенных задач, решаемых с помощью алгоритмов машинного обучения.

Ввиду того, что было разработано большое количество подходов к прогнозированию отказов жестких дисков, для автоматизации процесса прогнозирования отказов дисков систем хранения данных *Talin.Unified*, *Tatlin.Archive* целесообразно сначала произвести анализ разработанных подходов. Применение набора подходов для прогнозирования отказа жестких дисков в системах хранения данных с последующим сравнением результатов, полученных с помощью этих подходов, позволит выбрать наилучший подход для прогнозирования отказа жестких дисков и интегрировать его, повысив тем самым надежность хранения данных систем.

Постановка задачи

Целью данной работы является формулировка рекомендаций к прогнозированию отказов жестких дисков в системах хранения данных TATLIN.UNIFIED, TATLIN.ARCHIVE.

Для достижения этой цели в рамках выпускной квалификационной работы были поставлены следующие задачи.

- Выбрать набор модельных данных и исследовать его, сформулировав ряд закономерностей, характеризующих данные.
- Применить существующие подходы на наборе модельных данных.
- Использовать рассмотренные подходы на реальных данных жестких дисков системы TATLIN.UNIFIED, TATLIN.ARCHIVE.
- По результатам примененных подходов сформулировать рекомендации к анализу состояния диска.
- Оценить количество отказов дисков в 2024-2025 годах.

1. Существующие подходы к прогнозированию отказа жесткого диска

Существует несколько различных идей, которые могут использоваться для прогнозирования отказа жесткого диска — кластеризация, бинарная классификация, выявление аномалий.

1.1. Прогнозирование отказа жесткого диска с помощью решения задачи бинарной классификации

Прогнозирование отказа диска посредством решения задачи бинарной классификации осуществляется с помощью разделения дисков на два класса — отказавших и корректно работающих. Применение алгоритма бинарной классификации к S.M.A.R.T. параметрам диска позволит определить, к какому классу принадлежит рассматриваемый диск — к отказавшим дискам, или корректно работающим. Наличие временного ряда данных позволяет при таком подходе осуществить прогнозирование отказа диска по времени. Так как задача бинарной классификации — широко распространенная задача машинного обучения, первые подходы к прогнозированию отказов дисков основывались именно на решении задачи бинарной классификации.

1.1.1. Использование байесовского классификатора

Применение наивного байесовского классификатора [8] являлось одной из первых попыток применения методов машинного обучения к прогнозированию отказов жестких дисков. В данном исследовании было сделано предположение о том, что отказ жесткого диска невозможно спрогнозировать менее, чем за 48 часов до его отказа. На основе этого предположения класс отказавших жестких дисков был сформирован из записей, относящихся к последним 48 часам наблюдений за параметрами жесткого диска. Применение этого метода дало достаточно

низкую точность классификации — доля верных положительных классификаций составила 0.33 при доле 0.001 ложных положительных классификаций. Более поздние исследования применимости этого подхода к прогнозированию отказов жестких дисков дали сходные результаты [9].

Также для прогнозирования отказа жесткого диска использовался древовидный алгоритм Байеса [28], который показал 80% верных положительных классификаций при 3% ложных положительных классификаций. Однако при попытке снизить количество ложных положительных классификаций до 0% частота верных положительных классификаций алгоритма снизилась до 20-30%.

1.1.2. Использование метода опорных векторов

Метод опорных векторов, предложенный в [30], заключается в проектировании исходного набора векторов данных в пространство более высокой размерности и последующем поиске оптимальной разделяющей гиперплоскости [30]. Этот метод также одним из первых стал применяться для прогнозирования отказов дисков [16][17] и позволил классифицировать 50.6% отказов жестких дисков при 0% ложных положительных классификаций. Однако метод требует больших вычислительных ресурсов, и поэтому распространения в предсказывании отказов жестких дисков в режиме реального времени не получил.

1.1.3. Использование скрытой марковской модели

Хотя скрытые марковские модели, предложенные Баумом в 1966 [2], исторически широко применялись для задач распознавания речи, алгоритмы машинного обучения на основе марковских моделей были применены и для прогнозирования отказа жесткого диска [21]. В исследовании [21] авторы рассмотрели последовательности значений параметров жесткого диска, измеренных через равные промежутки времени и применили скрытые марковские модели для моделирования этих последовательностей. Подход с использованием скрытой марковской модели

позволил достичь 52% положительных классификаций при 0% ложных положительных классификаций, что сравнимо с результатом, полученным с помощью метода опорных векторов.

1.1.4. Метод K ближайших соседей

Метод K ближайших соседей, представленный в [6] — это метрический алгоритм классификации, основанный на вычислении оценок сходства между объектами. Для предсказания целевого признака для нового объекта x производятся следующие шаги:

- Вычисляются расстояния от x до всех объектов обучающей выборки;
- Объекты обучающей выборки сортируются по возрастанию расстояний до x ;
- Выбираются k объектов с наименьшими расстояниями до x ;
- По этим k объектам вычисляется ответ на задачу предсказания.

Данный метод, примененный для решения задачи классификации отказа жесткого диска [20], позволил идентифицировать наибольшее по сравнению с остальными методами количество отказов жестких дисков — 97% при 0.3% ложных положительных классификаций.

1.1.5. Метод случайного леса

Метод случайного леса, заключающийся в использовании набора решающих деревьев для решения задачи классификации, был представлен в [3] и сочетает в себе применение метода бэггинга для построения ансамбля деревьев и метода случайных подпространств.

Примененный для прогнозирования отказов жестких дисков, он показал худшие результаты по сравнению с методом K ближайших соседей, позволив идентифицировать 94.3% отказов дисков при 0.4% ложных положительных классификаций. Тем не менее этот результат является вторым по количеству идентифицированных отказавших дисков

среди рассмотренных подходов при одном из самых низких процентов ложных положительных классификаций.

1.2. Прогнозирование отказа жесткого диска с помощью решения задачи выявления аномалий

Хотя с помощью решения соответствующей задачи бинарной классификации для прогнозирования отказа дисков было разработано множество подходов, алгоритмы классификации являются алгоритмами обучения с учителем, то есть, требуют наличие на наборе данных разметки. В случае прогнозирования отказа дисков это означает, что для всех наблюдений собранных дисковых данных требуется также отметить, было это наблюдение сделано при сломанном диске, или при корректно работающем. В больших корпоративных системах, имеющих множество дисков, определить на лету, сломан тот или иной диск, очень трудно и ресурсоемко, поэтому наборы данных таких систем скорее всего не будут содержать разметку. Отсутствие разметки на реальных данных приводит к необходимости изучения методов машинного обучения для прогнозирования дисков, не ориентирующихся на разметку. Одним из таких подходов является интерпретация поведения близкого к поломке диска как аномалии, возникшей у корректно работающего диска. В такой интерпретации решение задачи прогнозирования отказа жесткого диска означает решение задачи выявления аномалий среди жестких дисков.

1.2.1. Isolation Forest

Выявление аномалий с помощью алгоритма изолированного леса, представленного в [13], было применено к прогнозированию отказов жестких дисков сравнительно недавно [24]. Алгоритм изолированного леса использует ансамбль деревьев и заключается в рекурсивном разделении набора данных по значению какого-либо случайно выбранного на текущем этапе признака. Так, в результате некоторого числа итераций деления набора данных, будет образовано дерево, а длина пути

от корня до листа, в котором находится тот или иной фрагмент рассматриваемых данных, характеризует степень аномальности этих данных. При случайном рекурсивном разбиении набора данных аномалии как правило имеют более короткие пути от корня дерева к листу, чем остальные элементы (ввиду того, что на определенном шаге алгоритма аномальные наблюдения будут изолированы от остальных по значению какого-либо признака). Алгоритм изолированного леса использует ансамбль деревьев, и в случае, если для ряда деревьев ансамбля какие-то элементы из набора данных имеют маленькое значение длины пути, скорее всего, они будут признаны аномальными. Данный подход показал результаты, значительно превосходящие результаты метода опорных векторов — 84.54% положительных классификаций при 0.0073% ложных положительных классификаций. Также стоит отметить, что хотя доля положительных классификаций у этого метода ниже, чем, например, у алгоритма случайного леса, доля ложных положительных классификаций у этого подхода значительно ниже, чем соответствующая доля ложных положительных классификаций алгоритма случайного леса: 0.0073% против 0.4%.

1.2.2. Использование расстояния Махаланобиса

Подход, использующий расстояние Махаланобиса [19] [32] для прогнозирования отказов жестких дисков, основан на вычислении расстояния Махаланобиса — обобщенном расстоянии, позволяющем измерить сходство между новым наблюдением и набором уже известных наблюдений с помощью рассмотрения корреляций между наблюдениями. Вычисленные значения расстояния Махаланобиса используются четырьмя оценщиками для вычисления значений, сравниваемых с пороговыми. Диск считается отказавшим, если результирующее значение какого-либо из оценщиков превысило пороговое значение.

Данный подход показал результаты, превосходящие метод опорных векторов — 67% положительных классификаций при 0% ложных положительных классификаций. Также подход, использующий расстояние Махаланобиса, значительно опередил метод опорных векторов в вычис-

лительной скорости, показав 4.3 минуты против 17983 минут, достигнутых методом опорных векторов. Этот показатель очень важен, так как низкая производительность метода опорных векторов являлась сдерживающим фактором в его использовании для прогнозирования отказов дисков на системах в режиме реального времени. Подход, использующий расстояние Махаланобиса, также позволил предсказать 56% отказов жестких дисков за 20 часов до отказа.

1.2.3. Использование автокодировщиков

Автокодировщики достаточно часто используются для выявления аномалий [15][33][25], и в частности они применяются и для выявления отказов жестких дисков [29]. В исследовании [29] рассмотрено несколько подходов к использованию автокодировщиков для выявления отказов жестких дисков.

Первый из подходов, описанных в [29] использует для классификации наличия отказа диска размер ошибки восстановления — если ошибка восстановления превышает пороговое значение, считается, что произошел отказ жесткого диска. Второй из подходов, описанных в [29] заключается в проверке сходства очередного объекта тренировочной выборки с остальными объектами в пространстве меньшей размерности с использованием расстояния Махаланобиса для измерения сходства. В случае, если расстояние Махаланобиса для очередного объекта превысило пороговое значение, считается, что произошел отказ жесткого диска. Третий подход, описанный в [29], является комбинацией метрик предыдущих двух подходов. Третий подход показал наибольшую частоту положительных классификаций по сравнению с первыми двумя — 28.09% при 10% ложных положительных классификаций. Результатов применения подходов при 0% ложных положительных классификаций представлено не было.

1.3. Прогнозирование отказа жесткого диска с помощью решения задачи кластеризации

Еще одним потенциально интересным подходом к прогнозированию отказов жестких дисков, не требующим разметки, является кластеризация данных. Кластеризация не применялась к прогнозированию жестких дисков ранее, но высокие результаты кластеризации данных дисков могли бы продемонстрировать наличие определенных моделей поведения дисков в рассматриваемом наборе данных. Низкие результаты кластеризации напротив демонстрируют невозможность выделить определенные поведения дисков, и в частности, выделить отказывающиеся диски.

1.3.1. KMeans

Алгоритм *KMeans* [14] группирует данные, пытаясь разделить выборки на n групп с одинаковой дисперсией, сводя к минимуму инерцию (*inertia*). Полагая, что *KMeans* разделяет набор данных из N элементов X на K не пересекающихся кластеров C , каждый из которых описывается средним μ_j элементов кластера, инерцию можно определить следующим образом:

$$\sum_{i=0}^n \min_{\mu_j \in C} (\|x_i - \mu_j\|^2) \quad (1)$$

Средние μ_j кластеров также называются центроидами. Недостатком алгоритма *KMeans* является то, что он требует указание количества кластеров для своей работы, которое влияет на качество полученной кластеризации. Оптимальное количество кластеров может варьироваться в зависимости от набора данных, на котором предполагается проводить кластеризацию.

1.3.2. Bisecting KMeans

Алгоритм *BisectingKMeans* [5] является итеративным вариантом алгоритма *KMeans*, использующим разделяющую иерархическую кла-

стеризацию. Вместо задания всех центроидов одновременно как это происходит в *KMeans*, центроиды выбираются динамически на основе результатов предыдущей кластеризации: кластер разбивается на два новых кластера до тех пор пока не будет достигнуто целевое количество кластеров.

1.3.3. Mean Shift

Алгоритм *MeanShift* направлен на обнаружение скоплений в наборе наблюдений равномерной плотности. Это алгоритм, основанный на итеративной корректировке центроидов таким образом, чтобы они были средним значением точек в заданной области. Затем эти центроиды фильтруются на этапе постобработки, чтобы исключить близкие к дубликатам центроиды и сформировать окончательный набор центроидов.

Положение центроидов корректируется с использованием метода, называемого восхождением на холм, который находит локальные максимумы расчетной плотности вероятности. Пусть на итерации t имеется центроид x , тогда центроид на итерации $t+1$ может быть вычислен следующим образом:

$$x^{t+1} = x^t + m(x^t) \quad (2)$$

где m есть сдвиг среднего значения. Пусть $K(x_i - x)$ — ядерная функция, $N(x)$ — окрестность x , то есть, набор точек, для которых $N(x_i) \neq 0$. Тогда сдвиг среднего значения m задается формулой 3.

$$m(x) = \frac{\sum_{x_i \in N(x)} K(x_i - x)x_i}{\sum_{x_i \in N(x)} K(x_i - x)} \quad (3)$$

Этот алгоритм не слишком хорошо масштабируется, так как требует поиска множества соседей на каждой итерации в процессе своей работы. В отличие от *KMeans* и *BisectingKMeans*, не требует задания количества кластеров для проведения кластеризации.

1.3.4. OPTICS

Алгоритм упорядочения точек для обнаружения кластерной структуры (*Ordering points to identify clustering structure, OPTICS*), представленный в [18], кластеризует данные на основе плотности. Он принимает на вход параметр ϵ , а также параметр *MinPts* — минимальное число точек, необходимое для образования кластера. Точка P называется основной точкой, если в ее окрестности $N_\epsilon(p)$ находятся минимум *MinPts* точек. Алгоритм состоит из следующей последовательности шагов:

- Выбирается случайная точка P .
- Вычисляются все точки, находящиеся в ее $N_\epsilon(p)$ окрестности, и кладутся в очередь.
- Найденным точкам присваиваются значения достижимости до основной точки и расстояние досягаемости.
- В случае, если P — не основная точка, берется следующая точка из очереди и процесс повторяется сначала.
- В случае, если P — основная точка, для каждой точки q в $N_\epsilon(p)$ обновляется ее расстояние досягаемости до основной точки. Все непосещенные ранее точки q складываются в очередь для дальнейшей обработки.
- В результате посещения всех точек алгоритмом получается набор расстояний досягаемости, на основании которых данные кластеризуются.

Данный алгоритм очень хорошо масштабируется и не требует указания количества кластеров для своей работы, поэтому может представить хорошие результаты при работе с таким большим набором данных, как множество параметров различных дисков.

1.3.5. Spectral Clustering

Алгоритм спектральной кластеризации, изложенный в [34], заключается в применении стандартных алгоритмов кластеризации (например, *KMeans*) на данных сниженной размерности. Алгоритм получает на вход некоторую матрицу сходства S размерности $\mathbb{R}^{n \times n}$ и целевое количество кластеров k и состоит из следующей последовательности шагов:

- построить на основе полученной матрицы сходства граф сходства;
- вычислить для построенного графа дискретный оператор Лапласа L ;
- вычислить k собственных векторов u_1, \dots, u_k из $Lu = \lambda Du$;
- составить матрицу $U \in \mathbb{R}^{n \times k}$, где столбцами являются векторы u_1, \dots, u_k ;
- считая $y_i \in \mathbb{R}^k$ для $i = 1 \dots n$ строками матрицы U , провести кластеризацию для $y_{i=1 \dots n} \in \mathbb{R}^k$ с помощью алгоритма кластеризации (*KMeans*) на кластеры C_1, \dots, C_k ;
- выдать в качестве результата набор кластеров A_1, \dots, A_k , где $A_i = \{j | y_j \in C_i\}$.

Алгоритм спектральной кластеризации требует указания количества кластеров, что усложняет его использование, так как оптимальное количество кластеров в кластеризации сильно зависит от набора данных.

1.3.6. DBSCAN

Алгоритм кластеризации *DBSCAN*, изложенный в [4], позволяет находить кластеры различной плотности в данных. В качестве центра кластера выбирается некоторая точка, такая, что на расстоянии от нее не большем ε , находится n точек. Количество точек n и расстояние

ϵ задают плотность образуемого кластера. Далее рекурсивно для каждой из n точек также отбираются точки, имеющие не меньше n соседей на расстоянии не большем ϵ . Кластер состоит из множества найденных таким образом точек. Точки, находящиеся на расстоянии большем ϵ от любого кластера, считаются алгоритмом выбросами. Алгоритм кластеризации *DBSCAN* не требует указания количества кластеров для своей работы. Возможность работать с кластерами различной плотности позволяет применять этот алгоритм на данных со сложными зависимостями, для которых не применимо евклидово расстояние в качестве метрики.

2. Применение подходов на наборе модельных данных

2.1. Выбор набора модельных данных

В большинстве исследований, приведенных в главе 1, применимость разработанных подходов к прогнозированию отказов жестких дисков оценивалась на каком-либо из следующих наборов данных [23]:

- *University of California dataset* (использовался, например, в [17])
- *Baidu dataset* (использовался, например, в [22])
- *Quantum Corporation dataset* (применялся в [20])
- *Backblaze dataset* (упоминался в [23])

Набор данных, предоставленный университетом Калифорнии использовался, например, в работах [16][17]. Недостатком этого набора данных является то, что его признаки не являются непосредственно *S.M.A.R.T.* параметрами, что снижает применимость выводов, сделанных на основе этого набора данных, к реальным данным, составленным из значений *S.M.A.R.T.*. Кроме того, набор данных университета Калифорнии был собран достаточно давно и поэтому гипотезы, сделанные на основе этих данных, могут быть не применимы к данным, собранным в настоящее время.

Набор данных корпорации *Quantum* использовался, например, в работе [8]. Так как этот набор данных имеет 11 признаков, соответствующих *S.M.A.R.T.* параметрам и был собран достаточно давно, гипотезы, опробованные на этом наборе данных, могут быть не применимы к реальным данным жестких дисков, имеющих более 200 *S.M.A.R.T.* параметров.

Из двух аналогичных наборов данных, предоставленных центрами обработки данных *Baidu* и *Backblaze*, был выбран предобработанный

набор данных² на основе данных центра *Backblaze*. Этот набор данных содержит данные одной модели жесткого диска *Seagate ST4000DM000* и содержит данные о 120 днях работы до отказа для отказавших дисков и 120 произвольных днях работы для дисков, работающих корректно.

Этот набор данных содержал дублирующие друг друга признаки, а также признаки, имеющие константные значения на всем наборе данных, что позволило в результате предобработки сократить количество признаков с 90 до 17.

2.2. Применение алгоритмов бинарной классификации

2.2.1. Гипотеза о важности *S.M.A.R.T.* параметров при классификации отказа диска

Следующие *S.M.A.R.T.* параметры считаются критически важными для прогнозирования отказа дисков³

- Количество перераспределенных секторов (*Reallocated sectors count*)
- Сквозная ошибка (*End-to-end error*)
- Сообщения о неисправимых ошибках (*Reported Uncorrectable Errors*)
- Текущее количество ожидающих секторов (*Current Pending Sector Count*)
- Количество неисправимых секторов (*Uncorrectable Sector Count*)

Исходя из того, что эти параметры считаются критическими, использование только их для обучения может улучшить характеристики модели. Справедливость данного предположения проверялась с помощью нескольких методов: метода опорных векторов, метода K ближай-

²<https://www.kaggle.com/datasets/awant08/hard-drive-failure-prediction-st4000dm000> Дата последнего обращения 30.04.2024

³https://en.wikipedia.org/wiki/Self-Monitoring,_Analysis_and_Reporting_Technology Дата последнего обращения 30.04.2024

ших соседей, метода случайного леса. Результаты работы методов измерялись с помощью метрик FAR — частоты ложных положительных классификаций и FDR (*Failure Detection Rate*) — отношения выявленных отказавших дисков к общему числу отказавших дисков.

2.2.2. Применение метода опорных векторов

Так как рассмотренный в разделе 1.1.2 метод опорных векторов одним из первых применялся к прогнозированию отказа жестких дисков, было принято решение оценить применимость этого метода к прогнозированию отказов жестких дисков модели *Seagate ST4000DM000*. Данный метод подтвердил свою низкую производительность в прогнозировании отказа жестких дисков и на 17 выделенных признаках за время, значительно превосходящее время обучения других моделей, не удалось обучить модель с использованием метода опорных векторов.

В результате применения данного метода к данным модели *Seagate ST4000DM000* на 5 признаках, соответствующих критическим параметрам *S.M.A.R.T.*, были достигнуты следующие метрики:

- $FDR = 1 - \frac{2812}{(2812 + 395)} = 0.123$
- $FAR = \frac{67}{95020} = 0.0007$

2.2.3. Применение метода K ближайших соседей

Метод K ближайших соседей был выбран ввиду того, что показал наибольшую точность 0.974% при 0.003% ложных положительных классификаций [23][20], а также не требовал предварительной подготовки для его использования, облегчая процесс проверки гипотезы.

В результате применения данного метода к данным модели *Seagate ST4000DM000* на 17 выделенных признаках были достигнуты следующие метрики:

- $FDR = 1 - \frac{740}{(740 + 2467)} = 0.769$

- $FAR = \frac{411}{95020} = 0.004$

В результате применения данного метода к данным модели *Seagate ST4000DM000* на 5 признаках, соответствующих критическим *S.M.A.R.T.*, были достигнуты следующие метрики:

- $FDR = 1 - \frac{2817}{(2817 + 390)} = 0.122$

- $FAR = \frac{64}{95020} = 0.0006$

2.2.4. Применение метода случайного леса

Метод случайного леса был выбран потому, что показал один из лучших результатов [23][20], классифицировав 0.943% отказов жестких дисков при 0.004 ложных положительных классификаций,

В результате применения данного метода к данным модели *Seagate ST4000DM000* на 17 выделенных признаках были достигнуты следующие метрики:

- $FDR = 1 - \frac{586}{(586 + 2621)} = 1 - 0.183 = 0.817$

- $FAR = \frac{212}{95020} = 0.002$

В результате применения данного метода к данным модели *Seagate ST4000DM000* на 5 признаках, соответствующих критическим *S.M.A.R.T.*, были достигнуты следующие метрики:

- $FDR = 1 - \frac{2808}{(2808 + 399)} = 0.124$

- $FAR = \frac{67}{95020} = 0.0007$

Использование при обучении только признаков, соответствующих *S.M.A.R.T.* параметрам, считающимся критическими, значительно увеличило количество ложных отрицательных классификаций, таким образом ухудшив характеристики модели. Таким образом, предположение о том, что использование только признаков, соответствующих критическим *S.M.A.R.T.* параметрам, улучшит показатели моделей, было

опровергнуто, и в дальнейшем при обучении предполагается использовать остальные *S.M.A.R.T.* параметры.

2.3. Применение алгоритмов выявления аномалий

Для оценки работы алгоритмов выявления аномалий используются те же метрики, что и для оценки работы алгоритмов бинарной классификации, а именно *FAR* — частота ложных положительных классификаций и *FDR* (*Failure Detection Rate*) — отношение выявленных отказавших дисков к общему числу отказавших дисков.

2.3.1. Isolation Forest

Алгоритм изолированного леса применялся в соответствии с проведенным исследованием о прогнозировании отказа дисков [24]. Было создано две модели, использующие алгоритм изолированного леса со значениями параметра *contamination* (равному доле наблюдений в наборе данных, которые следует идентифицировать как аномальные) равными 0.01 и 0.0002. В результате применения алгоритма изолированного леса со значением параметра *contamination* = 0.01 к данным были достигнуты следующие значения метрик:

- $FAR = \frac{886}{121910 + 886} = 0.0072$
- $FDR = 1 - \frac{3654}{4162 + 2} = 0.1225$

В результате применения алгоритма изолированного леса с *contamination* = 0.0002 к данным были достигнуты следующие значения метрик:

- $FDR = 1 - \frac{4162}{4162 + 2} = 0.0004$
- $FAR = \frac{35}{121910 + 35} = 0.0002$

Таким образом, применение изолированного леса со значением параметра *contamination* = 0.01 позволило достичь более низкой частоты ложных классификаций (*FAR*) при более высокой частоте детекции

отказавших дисков (FDR) по сравнению с результатами применения метода случайного леса, изложенными в 2. Дальнейшее повышение параметра *contamination* позволит достичь большего значения частоты классификации отказавших дисков.

2.3.2. Расстояние Махаланобиса

Алгоритм выявления аномалий с помощью расстояния Махаланобиса был реализован в соответствии с исследованием [19] [32]. В результате выявления аномалий с помощью расстояния Махаланобиса были достигнуты следующие метрики:

- $FDR = 1 - \frac{3970}{3970 + 194} = 0.0466$
- $FAR = \frac{712}{122084 + 712} = 0.0058$

Так как алгоритм использует 4 оценщика, зависящих от заданных параметров, в процессе своей работы, результаты работы алгоритма зависят как от набора данных, так и от того, насколько оптимально подобраны заданные параметры. Потенциально текущие результаты могут быть улучшены, так как подбор оптимальных параметров оценщиков не проводился.

2.4. Применение алгоритмов кластеризации

2.4.1. Применение метода главных компонент для сокращения размерности набора данных

Работа алгоритмов кластеризации требует много ресурсов, поэтому применение их напрямую к набору данных жестких дисков, содержащему множество признаков, может занять очень большое количество времени. Так как рассматриваемый набор данных жестких дисков даже после очистки содержит большое количество признаков, для применения алгоритмов кластеризации было полезно сократить размерность данных. Для этого использовался метод главных компонент [27], являющийся одним из наиболее распространенных методов для снижения

Таблица 1: PCA on open data

Размерность данных	Количество информации
4	80%
7	95%

размерности данных. Результаты применения метода главных компонент, представленные в таблице 1 показали, что снижение размерности данных до 4 позволит сохранить 80% информации о наборе данных дисков, снижение размерности данных до 7 позволит сохранить 95% информации соответственно.

К набору данных сниженной размерности было применено несколько алгоритмов кластеризации, описанных в 1. Для сравнения алгоритмов кластеризации используются метрики, отличные от метрик, использующихся для оценки решений задачи классификации. Так как набор данных обладает разметкой, для повышения точности измерения работы различных алгоритмов кластеризации использовались метрики, учитывающие наличие разметки: скорректированный индекс Рэнда (ARI) [11], скорректированная взаимная информация (AMI) [31], индекс Фаулкса-Мэллоуза (FMI) [7].

Определение 2.4.1 *Скорректированный индекс Рэнда (ARI) — метрика, отражающая меру подобия между двумя кластерами. Пусть C — кластеризация, заданная разметкой, K — кластеризация, полученная с помощью алгоритма, a — количество пар элементов, которые попали в один кластер кластеризации C и в один кластер кластеризации K , b — количество пар элементов, которые попали в разные кластеры кластеризации C и в разные кластеры кластеризации K . Тогда скорректированный индекс Рэнда может быть выражен следующей формулой:*

$$ARI = \frac{RI - \mathbb{E}[RI]}{\max(RI) - \mathbb{E}[RI]} \quad (4)$$

RI есть нескорректированный индекс Рэнда, который выражается следующим образом:

$$RI = \frac{a + b}{C_2^{n_{samples}}} \quad (5)$$

где $C_2^{n_{samples}}$ — число всевозможных пар в рассматриваемом наборе данных.

Определение 2.4.2 Пусть U, V есть две разметки на N объектах. Их энтропия $H(U), H(V)$ определяется следующим образом:

$$H(U) = - \sum_{i=1}^{|U|} P(i) * \log P(i) \quad (6)$$

$$H(V) = - \sum_{j=1}^{|V|} \hat{P}(j) * \log \hat{P}(j) \quad (7)$$

Где $P(i) = U_i/N$ и $\hat{P}(j) = |V_j|/N$. Их взаимная информация может быть выражена следующей формулой:

$$MI(U, V) = \sum_{i=1}^{|U|} \sum_{j=1}^{|V|} \frac{|U_i \cap V_j|}{N} \log \left(\frac{N|U_i \cap V_j|}{|U_i||V_j|} \right) \quad (8)$$

и математическое ожидание взаимной информации может быть выражено следующим образом:

$$\begin{aligned} \mathbb{E}[MI] = & \sum_{i=1}^{|U|} \sum_{j=1}^{|V|} \sum_{n_{ij}=(a_i+b_j-N)^+}^{\min(a_i, b_j)} \frac{n_{ij}}{N} \log \left(\frac{N n_{ij}}{a_i b_j} \right) * \\ & * \frac{a_i! b_j! (N - a_i)! (N - b_j)!}{N! n_{ij}! (a_i - n_{ij})! (b_j - n_{ij})! (N - a_i - b_j + n_{ij})!} \end{aligned} \quad (9)$$

где $a_i = |U_i|$ и $b_j = |V_j|$ (число элементов в U_i и в V_j соответственно) и $(a_i + b_j - N)^+$ есть $\max(0, a_i + b_j - N)$. Тогда скорректированная взаимная информация может быть выражена следующим образом:

$$AMI = \frac{MI - \mathbb{E}[MI]}{\text{mean}(H(U), H(V)) - \mathbb{E}[MI]} \quad (10)$$

Определение 2.4.3 Индекс Фаулкса-Мэллоуза определяется как среднее геометрическое точности и полноты и определяется следующим образом:

$$FMI = \frac{TP}{\sqrt{(TP + FP)(TP + FN)}} \quad (11)$$

где TP (*True Positive*) — число пар точек, которые принадлежат к одним и тем же кластерам для обеих кластеризаций, FP (*False Positive*) — число пар точек, которые принадлежат к одним и тем же кластерам для кластеризации, задаваемой разметкой, и принадлежат к разным кластерам для предсказанной кластеризации, FN (*False Negative*) — число пар точек, которые принадлежат к разным кластерам для кластеризации, задаваемой разметки и к одному кластеру в случае предсказанной кластеризации.

2.4.2. Сравнительный анализ алгоритмов кластеризации

Результаты применения алгоритмов кластеризации *KMeans*, *Bisecting KMeans*, *Spectral Clustering*, *Mean Shift*, *OPTICS* на наборе данных сниженных размерностей 4 и 7 представлены в таблице 2.

Таблица 2: HDD failure prediction using clustering methods

Алгоритм	Размерность данных	Время обучения, сек	ARI	AMI	FMI
KMeans	4	1.712	0.001	0.002	0.686
KMeans	7	1.802	0.001	0.002	0.686
OPTICS	4	3170.495	0.0	0.011	0.310
OPTICS	7	4749.342	0.0	0.008	0.305
MeanShift	4	12067.558	0.0	0.0	0.970
MeanShift	7	21211.853	0.003	0.004	0.962
SpectralClustering	4	32619.471	0.005	0.003	0.005
SpectralClustering	7	25367.726	0.005	0.001	0.936
DBSCAN	4	14566.119	0.002	0.001	0.001
DBSCAN	7	33742.266	0.002	0.003	0.876

Для измерения качества кластеризации использованы приведенные в 2.4.1, 2.4.2, 2.4.3 метрики ARI , AMI , FMI . В результате анализа таблицы можно сделать вывод, что проведение кластеризации для рассматриваемого набора данных показало плохие результаты для всех алгоритмов — так, например, максимальное значение ARI не превышает 0.005, что свидетельствует о том, что метки кластеров расставлены на данных почти случайным образом. Это демонстрирует то, что из рас-

смотренных данных жестких дисков не удалось выделить некоторые общие модели поведения жестких дисков.

2.5. Анализ примененных подходов

В исследовании были рассмотрены три подхода к прогнозированию отказа жестких дисков: прогнозирование отказа жесткого диска с помощью решения задачи бинарной классификации, с помощью решения задачи выявления аномалий, прогнозирование с помощью кластеризации. Недостатком примененных подходов, основывающихся на решении задачи бинарной классификации, является необходимость разметки набора данных, которую трудно получить для реальных данных жестких дисков, собранных с корпоративных систем. Подходы к прогнозированию, основывающиеся на выявлении аномалий, не требуют разметки. В исследовании они показали более низкие доли детекции отказавших дисков по сравнению с алгоритмами бинарной классификации. Доли ложных классификаций у этих алгоритмов также значительно ниже алгоритмов бинарной классификации, поэтому эти алгоритмы потенциально позволят классифицировать большее количество отказавших дисков при соответствующем повышении частот ложных классификаций. Также для прогнозирования отказа жестких дисков были применены различные алгоритмы кластеризации. Применение алгоритмов кластеризации показало низкие результаты, что может говорить либо о недостаточности данных, либо о том, что для рассматриваемого набора данных нельзя выделить несколько явных моделей поведения, на которые в дальнейшем можно было бы кластеризовать диски. Таким образом, для рассматриваемого набора данных с точки зрения применимости на реальных системах наиболее перспективным оказался подход прогнозирования отказа дисков с помощью выявления аномалий.

3. Применение подходов на реальных данных

С ростом продаж системы хранения данных *Tatlin.Unified* компании *Yadro* выросло количество обращений пользователей этих систем о замене жесткого диска, сбоящего в той или иной системе. Каждое такое обращение требует времени на верификацию состояния диска инженером поддержки с последующей его заменой в случае, если диск действительно отказал. Зачастую точно установить факт отказа диска нельзя — тогда во избежание возможного его отказа, потенциально приводящего к потере данных, этот диск в системе хранения все равно заменяется. Замененный диск не может быть использован в дальнейшем для каких-либо других целей, так как потенциально содержит конфиденциальные пользовательские данные — поэтому такие диски утилизируют, приводя их в полностью неработоспособное состояние. Возросшее количество случаев замены дисков в системах хранения данных *Tatlin.Unified* привело к увеличению расходов компании на диагностику таких дисков и закупку новых, поэтому задача автоматизации и улучшения анализа дисков с целью уменьшения ложноположительных классификаций дисков как отказавших стала приоритетной.

3.1. Формирование набора данных

Для сбора информации, необходимой для анализа подозрительных дисков, в компании было доступно два источника данных — система отслеживания инцидентов *Naumen*, а также система сбора отчетов о состоянии систем хранения данных *SYR*, содержащая, в частности, отчеты о состояниях дисков. Для проведения дальнейшего анализа надлежит рассмотреть данные, предоставляемые каждой из этих систем, отдельно.

3.1.1. Набор данных *Naumen*

В системе отслеживания инцидентов *Naumen* на каждый подозрительный диск заводится инцидент, за обработку которого в дальнейшем ответственен инженер поддержки — он верифицирует состояние диска, запуская различные диагностические команды. В частности, обязательным этапом анализа диска является вызов команды для сбора *S.M.A.R.T.* параметров диска и последующий их анализ. Например, для диска */dev/sda* команда вызова выглядит следующим образом: *smartctl -a /dev/sda*. Эта команда позволяет собрать набор *S.M.A.R.T.* параметров для *SAS* дисков, представленный в таблице 3. Набор параметров, предоставляемых *SAS* диском, отличается от набора параметров, предоставляемых *SATA* диском, на которых проводились все доступные на текущий момент исследования, поэтому для анализа дисков в дальнейшем будут рассматриваться все параметры *S.M.A.R.T.*.

Таблица 3: Доступные *S.M.A.R.T.* параметры

<i>Название S.M.A.R.T. параметра</i>
Current Drive Temperature
Drive Trip Temperature
Manufactured in week
Specified cycle count over device lifetime
Accumulated start-stop cycles
Specified load-unload count over device lifetime
Accumulated load-unload cycles
Read/Write/Verify errors corrected by ECC fast/delayed
Read/Write/Verify errors corrected by rereads/rewrites
Read/Write/Verify total errors corrected
Read/Write/Verify correction algorithm invocations
Read/Write/Verify total uncorrected errors
Elements in grown defect list

Результаты выполнения диагностических команд прикладываются в качестве комментария к инциденту в системе отслеживания инцидентов *Naumen*. Таким образом, данные параметров *S.M.A.R.T.* о диске в

Naumen содержатся в необработанных текстах комментариев и требуют синтаксического анализа для формирования сопоставления диску его параметров в момент заведения инцидента.

Также в одном инциденте может быть упомянуто сразу несколько дисков — в этом случае для каждого из этих дисков требуется выделить соответствующие ему *S.M.A.R.T.* параметры, содержащиеся в комментариях.

Признаки данных *Naumen*, необходимые для дальнейшего анализа диска, и примеры их значений, приведены в таблице 4. Остальные признаки данных *Naumen* не приведены и не участвуют в анализе диска.

Таблица 4: Пример наблюдения в наборе данных *Naumen*

Номер инцидента	Время создания инцидента	Номер комментария в инциденте	Идентификатор диска	<i>S.M.A.R.T.</i> параметры диска ...
INC511868	17.07.2021 07:03	comment26501144	9RHNP3DC	...

В таблице 4 колонка "Номер инцидента" соответствует колонке с номером инцидента в собранном наборе данных, колонка "Время создания инцидента" содержит время, в которое был заведен инцидент в системе *Naumen*, колонка "Номер комментария в инциденте" содержит номер комментария в указанном инциденте, из которого выделены *S.M.A.R.T.* параметры диска в рассматриваемом наблюдении. Колонка "Идентификатор диска" содержит идентификатор диска в системе — его серийный номер. Колонка "*S.M.A.R.T.* параметры диска" соответствует набору колонок, содержащих значения *S.M.A.R.T.* параметров в собранном наборе данных *Naumen*.

3.1.2. Набор данных *SYR*

Система сбора отчетов о состоянии систем хранения данных *SYR* (*Simple Yadro Reporting*) собирает отчеты о состоянии каждой компоненты системы — в частности, дисков. Один отчет о состоянии системы хранения данных *SYR* содержит в себе все диски системы. Смена состояний диска отслеживается с помощью соответствующих событий:

DiskDriveEvents+OwnerUnbound означает, что диск отказал и не доступен в системе. Событие *DiskDriveEvents+DiskDriveCreated* означает, что диск добавили в систему. Также есть события, отражающие различные действия, проводимые над диском в процессе его функционирования: *DiskDriveEvents+SlotChanged* отражает смену позиции подключения диска, и т.д.. Среди всех возможных событий только событие *DiskDriveEvents+OwnerUnbound* свидетельствует о поломке диска, в случае остальных событий диск можно считать корректно работающим. Таким образом, диск может быть в двух состояниях — отказать (в случае события *DiskDriveEvents+OwnerUnbound*), и корректно работать (в случае всех остальных событий). В отчете о состоянии диска содержится только время отчета и состояние диска, при этом период сбора отчетов достаточно велик. Это объясняется тем, что проведение регулярного опрашивания систем, находящихся в эксплуатации у пользователей, с целью сбора отчетов о состоянии, подвергает их дополнительной нагрузке, которая может значительно влиять на работоспособность.

Признаки данных *SYR*, необходимые для дальнейшего анализа диска, и примеры их значений, приведены в таблице 5. Остальные признаки данных *SYR* не приведены и не участвуют в анализе диска.

Таблица 5: Пример наблюдения в наборе данных *SYR*

Дата отчета	Идентификатор диска	Состояние диска в момент отчета
17.07.2021 07:03	9RHP142L	DiskDriveEvents+DiskDriveCreated

Колонка «Дата отчета» соответствует дате собранного отчета о состоянии системы хранения данных (ее дисков), колонка «Идентификатор диска» содержит идентификатор диска — его серийный номер, колонка «состояние диска в момент отчета» содержит соответствующее событие обслуживания диска: *DiskDriveEvents+OwnerUnbound* и другие.

3.1.3. Слияние данных *Naumen* и *SYR*

Из рассмотренных данных *Naumen* и *SYR* можно сформировать единый набор наблюдений, состоящий из снимка *S.M.A.R.T.* параметров, приведенных в *Naumen* и состояния диска (разметки), взятого из *SYR*. Состояние диска из системы *SYR* сопоставляется совокупности *S.M.A.R.T.* параметров диска из *Naumen* по серийному номеру диска. Для снимка *S.M.A.R.T.* параметров из *Naumen* берется ближайший по времени, следующему за датой создания инцидента, отчет о состоянии системы — состояние диска в таком отчете отображает результат обработки инцидента. Например, *DiskDriveEvents+OwnerUnbound* в случае выявленного в процессе работы над инцидентом отказа диска.

Таким образом, сформированный набор данных представляет собой снимок *S.M.A.R.T.* параметров диска и его состояния. Такие данные предоставляют возможность для применения алгоритмов классификации и кластеризации к анализу отказа дисков, так как признак состояния диска может рассматриваться в качестве разметки. Получившиеся данные имеют 95 признаков и состоят из 24823 различных наблюдений.

3.2. Кластеризация сформированного набора данных

Так как в процессе диагностики состояния диска из инцидента иногда происходят ложноположительные замены дисков — то есть, корректно работающий диск заменяется и числится как отказавший, имеющаяся разметка также склонна к ложноположительным классификациям. Таким образом, на основании имеющихся данных не представляется возможным обучить точный классификатор состояния дисков. Чтобы улучшить качество разметки дисков, необходимо исследовать данные на наличие определенных моделей поведения, и оценить их взаимосвязь со статусом диска. Для проведения такого анализа используются методы кластеризации, не ориентирующиеся на разметку.

Для проведения кластеризации необходимо было выбрать множество *S.M.A.R.T.* параметров, по которым кластеризовать данные. Для этого *S.M.A.R.T.* параметры *SATA* дисков, считающиеся критически

Таблица 6: Сопоставление *S.M.A.R.T.* параметров

<i>SATA S.M.A.R.T.</i> параметр	<i>SAS S.M.A.R.T.</i> параметр
Reported Uncorrectable Errors	Total uncorrected errors read/write
Reallocated sectors count	Elements in grown defect list

важными, упомянутые в главе 2.2.1, были сопоставлены *S.M.A.R.T.* параметрам *SAS* дисков в соответствии со спецификацией протокола *SCSI* ⁴. Так, параметру *Reported Uncorrectable Errors* были сопоставлены параметры *Total uncorrected errors read* и *Total uncorrected errors write*, в соответствие параметру *Reallocated sectors count* был поставлен параметр *Elements in grown defect list*. Сопоставление параметров представлено на таблице 6.

Дополнительной задачей при проведении кластеризации стало выявление моделей поведения дисков, являющихся специфичными для компаний-производителей дисков (вендоров). Нахождение таких особенностей важно для улучшения диагностики диска, так как специфичные компании-производителю значения определенных характеристик диска могут быть интерпретированы инженером как аномальное поведение и стать поводом для ненужной замены корректно работающего диска. Так, например, кластеризация проводилась также для параметров *Compliance* — версии спецификации, в соответствии с которой было реализовано программное обеспечение диска, *Product* — модели диска, *Revision* — версии поставки диска на систему хранения данных. Далее будут представлены результаты нахождения особенностей дисков, специфичных компании-производителю, а также результаты кластеризации дисков по выбранным *S.M.A.R.T.* параметрам. Так как взаимосвязи между данными дисков сложны, были выбраны алгоритмы кластеризации, работающие с неевклидовым расстоянием в качестве метрики — *DBSCAN*, *HDBSCAN*.

⁴<https://www.seagate.com/files/staticfiles/support/docs/manual/Interface%20manuals/100293068j.pdf> Дата последнего обращения 30.04.2024

3.2.1. Кластеризация *S.M.A.R.T.* параметров

Результаты применения алгоритмов *DBSCAN*, *HDBSCAN* к параметрам *Elements in grown defect list*, *Total uncorrected errors read*, *Total uncorrected errors write* представлены на графиках 1, 2. Для визуализации найденных кластеров использовалось три различных способа проектирования данных на двумерное пространство — *PCA*, *t-SNE*, *UMAP*. Из графика 1 видно, что кластеризация с помощью алгоритма *DBSCAN* не выделила значительных кластеров в данных. Из графика 2 видно, что кластеризация с помощью алгоритма *HDBSCAN* выделила в данных дисков кластер — на визуализации с помощью *t-SNE* этот кластер представлен кругом.




Рис. 1: Визуализация кластеров *DBSCAN* для *Elements in grown defect list*, *Total Uncorrected Errors Read/Write*

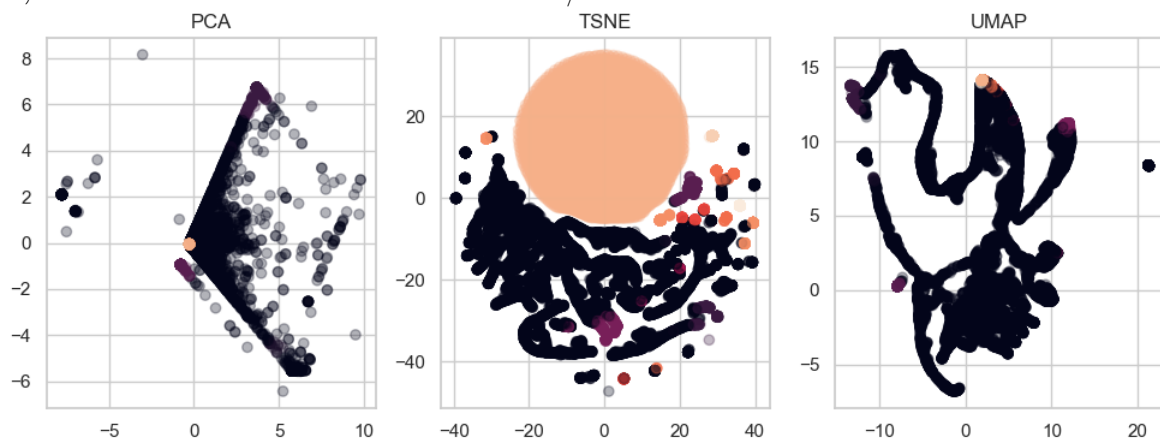


Рис. 2: Визуализация кластеров *HDBSCAN* для *Elements in grown defect list*, *Total Uncorrected Errors Read/Write*

Разница в результатах работы алгоритмов *DBSCAN*, *HDBSCAN* объ-

Таблица 7: Результаты кластеризации для *Total uncorrected errors write*

Алгоритм кластеризации	Показатель силуэта
HDBSCAN	0.316
DBSCAN	0.562

ясняется тем, что кластеры в данных дисков имеют различную плотность. Поэтому эти кластеры получилось выделить только с помощью алгоритма *HDBSCAN*, работающего с кластерами различной плотности, и не удалось выделить с помощью алгоритма *DBSCAN*.

Результаты работы алгоритмов также были измерены с помощью *коэффициента силуэта кластера* и представлены в таблице 7. Не очень высокие значения коэффициента силуэта кластера объясняются тем, что оба алгоритма выявили большое количество маленьких кластеров дисков, которые оказались слабо отличимы от остальных. Для повышения коэффициента силуэта кластера необходимо при работе алгоритмов *DBSCAN*, *HDBSCAN* задавать большее расстояние ε между двумя наблюдениями дисков, а также большее число наблюдений n , необходимое для того, чтобы считать наблюдение центром некоторого кластера, как описано в главе 1.3.6. В случае с *HDBSCAN* также необходимо повысить размерность группы дисков, необходимых для образования кластера. Следует отметить, что невысокое значение коэффициента силуэта кластера в рассматриваемом случае не является проблемой, так как два самых крупных кластера, анализ которых будет проводиться далее, описывают большую часть данных.

Анализ кластеров, полученных с помощью алгоритма кластеризации *HDBSCAN*, показал, что большинство данных было разбито на два крупных кластера — кластер с нулевыми значениями каждого из параметров *Elements in grown defect list*, *Total uncorrected errors read*, *Total uncorrected errors write*, и кластер, где какой-либо из параметров имеет ненулевое значение.

В таблице 8 представлена статистика отказов дисков по кластерам. Сравнительный анализ значений статусов дисков в этих кластерах показал, что отказавших дисков в кластере с нулевыми значениями пара-

Таблица 8: Отказы дисков в кластерах *Elements in grown defect list*, *Total uncorrected errors read*, *Total uncorrected errors write*

Кластер	Число отказов	Число корректно работающих	Размерность кластера	Процент отказов
Кластер 1	2019	10880	12899	15.6%
Кластер 2	4875	4711	9586	50.8%

метров значительно меньше. Таким образом, при диагностике отказов дисков можно рекомендовать проверять значения параметров *Elements in grown defect list*, *Total uncorrected errors read*, *Total uncorrected errors write* — если какой-то из параметров имеет ненулевое значение, вероятность того, что диск действительно отказал, существенно выше.

3.2.2. Кластеризация *Drive Trip Temperature*

Результаты применения алгоритмов *DBSCAN*, *HDBSCAN* к параметрам *Elements in grown defect list*, *Total uncorrected errors read*, *Drive Trip Temperature* представлены на графиках 3, 4. Для визуализации найденных кластеров использовалось три различных способа проектирования данных на двумерное пространство — *PCA*, *t-SNE*, *UMAP*.

Из графика 3 видно, что кластеризация через алгоритм *DBSCAN* разделила данные на два кластера, а кластеризация с помощью алгоритма *HDBSCAN* на три. Результаты работы алгоритмов также были измерены с помощью *коэффициента силуэта кластера* и представлены в таблице 9. Невысокие значения коэффициентов силуэта кластера как и в предыдущем случае объясняются тем, что алгоритмами помимо двух основных кластеров в случае с *DBSCAN* и трех основных кластеров в случае с *HDBSCAN* также был найден ряд других небольших кластеров, слабо отличимых от остальных данных. Лучший подбор параметров алгоритмов позволит существенно повысить коэффициент силуэта кластера. Следует отметить, что невысокое значение коэффициента силуэта кластера в рассматриваемом случае не является проблемой, так как два самых крупных кластера в случае *DBSCAN* и три самых крупных кластера в случае с *HDBSCAN*, анализ которых будет




Рис. 3: Визуализация кластеров *DBSCAN* для *Elements in grown defect list*, *Total uncorrected errors read*, *Drive Trip Temperature*

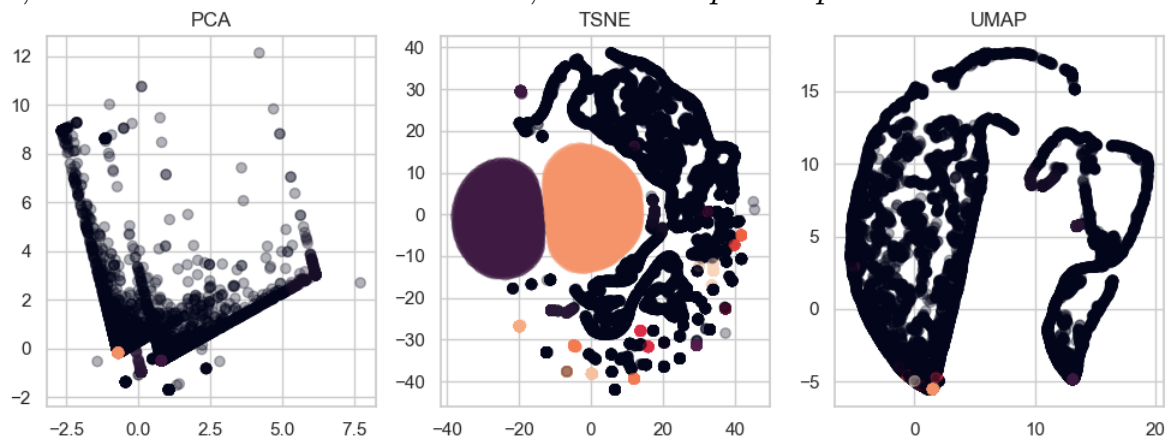


Рис. 4: Визуализация кластеров *HDBSCAN* для *Elements in grown defect list*, *Total uncorrected errors read*, *Drive Trip Temperature*

проводиться далее, описывают большую часть данных.

Анализ найденных с помощью алгоритма *DBSCAN* кластеров показал, что все имеющиеся диски имеют два возможных значения предельной температуры *Drive Trip Temperature* — 60°C и 85°C . Статистика о найденных значениях предельной температуры среди разных кластеров представлена в таблице 10.

Кластеры, найденные помощью алгоритма *HDBSCAN*, повторяют кластеры, найденные для параметров *Elements in grown defect list* и *Total uncorrected errors read* — большинство данных делится на кластер из нулевых значений параметров *Elements in grown defect list* и *Total uncorrected errors read* с разным значением предельной температуры, и два кластера с ненулевыми значениями параметров *Elements*

Таблица 9: Результаты кластеризации для *Elements in grown defect list*, *Total uncorrected errors read*, *Drive Trip Temperature*

Алгоритм кластеризации	Показатель силуэта
HDBSCAN	0.262
DBSCAN	0.592

Таблица 10: Температура дисков в кластерах *Elements in grown defect list*, *Total uncorrected errors read*, *Drive Trip Temperature*

Кластер	Температура	Размерность кластера	Компания-производитель
Кластер 1	85C	15129	Western Digital
Кластер 2	60C	8976	Seagate

in grown defect list и *Total uncorrected errors read* со значением предельной температуры 60C и 85C соответственно. Так как результаты алгоритма *HDBSCAN* аналогичны результатам алгоритма *DBSCAN*, более подробный анализ кластеров проводиться не будет.

Таким образом, кластеризация данных дисков с использованием параметра *Drive Trip Temperature* позволила выявить особенность поведения дисков, специфичную компании-производителю: диски компании *Seagate* имеют предельную температуру 60C, тогда как диски компании *Western Digital* имеют предельную температуру 85. Это поведение важно учитывать при анализе параметра текущей температуры диска *Current Drive Temperature* в процессе диагностики состояния диска — нормальность значения текущей температуры диска зависит от его предельной температуры, определяемой компанией-производителем.

3.2.3. Кластеризация *Compliance*

Результаты применения алгоритмов *DBSCAN*, *HDBSCAN* к параметрам *Elements in grown defect list*, *Total uncorrected errors read*, *Compliance* представлены на графиках 5, 6. Для визуализации найденных кластеров использовалось три различных способа проектирования данных на двумерное пространство — *PCA*, *t-SNE*, *UMAP*.

Из графиков 5, 6 видно, что кластеризация с помощью алгоритмов *DBSCAN*, *HDBSCAN* разделила данные на два непересекающихся кла-

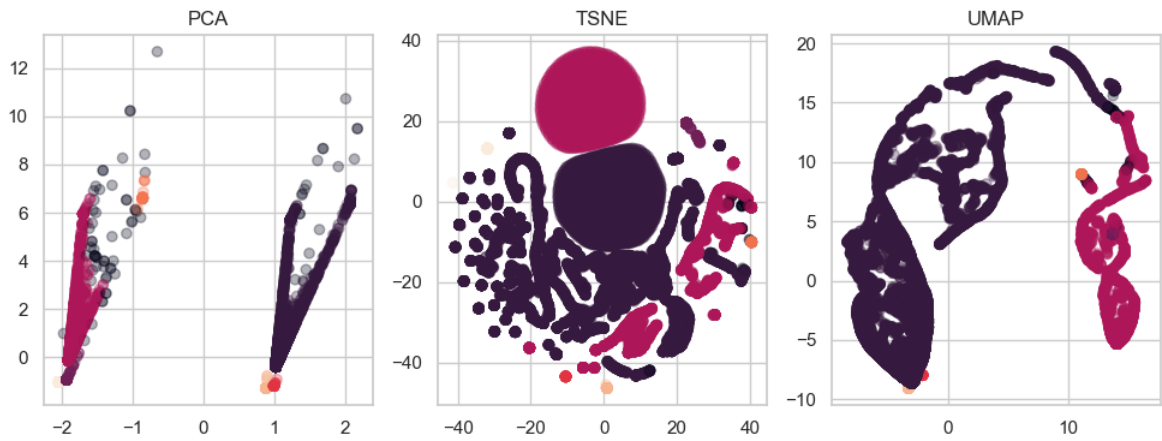


Рис. 5: Визуализация кластеров *DBSCAN* для *Elements in grown defect list*, *Total uncorrected errors read*, *Compliance*




Рис. 6: Визуализация кластеров *HDBSCAN* для *Elements in grown defect list*, *Total uncorrected errors read*, *Compliance*

стера по значению признака *Compliance*. Результаты работы алгоритмов также были измерены с помощью *коэффициента силуэта кластера* и представлены в таблице 11. Невысокие значения коэффициентов силуэта кластера как и в предыдущем случае объясняются тем, что алгоритмами помимо двух основных кластеров в случае с *DBSCAN* и трех основных кластеров в случае с *HDBSCAN* также был найден ряд других небольших кластеров, слабо отличимых от остальных данных. Лучший подбор параметров алгоритмов позволит существенно повысить коэффициент силуэта кластера. В дальнейшем анализе как и в предыдущем случае будут рассматриваться только самые крупные кластеры, описывающие большую часть данных.

Стоит отметить, что так как признак *Compliance* категориальный

Таблица 11: Результаты кластеризации для *Elements in grown defect list*, *Total uncorrected errors read*, *Compliance*

Алгоритм кластеризации	Силуэт
HDBSCAN	0.245
DBSCAN	0.553

Таблица 12: Отказы дисков в кластерах *Elements in grown defect list*, *Total uncorrected errors read*, *Compliance*

Кластер	Число дисков Western Digital	Число дисков Seagate	Размерность кластера
Compliance SPC-4	14368	1451	15819
Compliance SPC-5	796	7512	8308

и принимает два значения *SPC-4*, *SPC-5*, применение алгоритмов кластеризации для него оказалось избыточным — данные разделились по значению этого признака.

При сравнительном анализе получившихся кластеров — дисков со значением *Compliance* равным *SPC-5* и дисков со значением *Compliance* равным *SPC-4*, было выявлено, что большинство дисков компании *Seagate* имеют значение *Compliance* равным *SPC-5*. Большинство дисков компании *Western Digital* имеют значение *Compliance* равным *SPC-4*. Статистика о значениях *Compliance* представлена в таблице 12.

Так как в компании *Yadro* диски *Seagate* стали закупать не так давно, реализация в соответствии с более свежей версии спецификации *SPC-5* может быть не столько специфической особенностью компании-производителя, сколько следствием более поздней даты производства диска. Это же объясняет наличие реализации в соответствии со спецификацией *SPC-5* небольшого количества дисков компании *Western Digital*.

4. Построение оценки числа отказов дисков на 2025 год

Помимо автоматизации анализа отказа конкретного экземпляра диска, также стояла задача оценить совокупное количество отказов дисков на всех системах хранения данных, чтобы компания *Yadro* могла запланировать закупки соответствующего числа новых дисков. Для построения такой оценки были рассмотрены все случаи отказов дисков на 1377 системах хранения данных *Tatlin.Archive*, *Tatlin.Unified*, зафиксированные в системе хранения отчетов *SYR* в период с 30.04.2019 по 31.01.2024. На графике 7 продемонстрирован помесечный рост числа замененных дисков.




Рис. 7: Число замененных дисков в месяц

Из приведенного графика видно, что резкий рост числа заменяемых дисков в месяц начался с третьего квартала 2022 года, пережил незначительный спад в третьем квартале 2023 и продолжился далее. Наибольшее число замен дисков было достигнуто в декабре 2023 года. Чтобы оценить зависимость вероятности отказа диска от количества месяцев его работы, необходимо было исследовать среднее число дней работы диска в системе хранения.

Из гистограммы 8, отражающей количество дисков, отработавших то или иное число дней, видно, что большинство дисков функционируют от 1200 до 1400 дней. Следует отметить, что множество дисков,

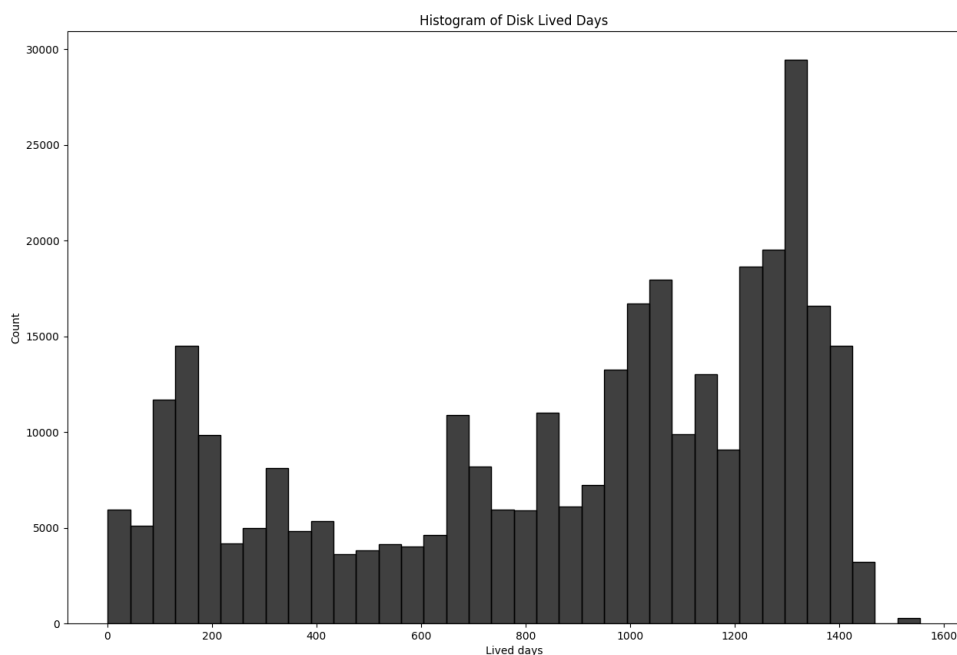


Рис. 8: Распределение числа дней работы дисков

функционирующих большее число дней, содержит множество дисков, работающих без отказа меньшее число дней. Этот факт учтен при составлении рассматриваемой гистограммы — на ней множество дисков, корректно работающих, например, 200 дней, состоит только из дисков, проработавших ровно 200 дней и не включает в себя диски, которые работали большее число дней (аналогично для другого произвольного числа дней, представленного на гистограмме).

Помимо визуального анализа зависимости частоты отказа диска от времени его работы с использованием гистограммы был произведен поквартальный подсчет частот отказов дисков в период с 30.04.2019 по 31.01.2024, представленный в таблице 13. Собранная статистика подтверждает визуальный анализ — вероятность отказа диска на четвертый год работы выше, чем в остальные периоды, и составляет от 6.9% (вероятность отказа в первом квартале четвертого года работы) до 9.7% (вероятность отказа во втором квартале четвертого года работы). На основании подсчитанных долей отказавших дисков за 18 кварталов в период с 30.04.2019 по 31.01.2024, представленных в таблице 13, верхняя

Таблица 13: Зависимость частоты отказа дисков от времени

Количество месяцев	Общее число дисков	Число отказавших дисков	Число корректно работающих дисков	Частота отказа
3мес	332071	288	331783	0.000867
6мес	295370	438	294932	0.001483
9мес	281355	320	281035	0.001137
1г	272044	319	271725	0.001173
1г 3мес	261615	307	261308	0.001173
1г 6мес	252120	253	251867	0.001003
1г 9мес	245578	389	245189	0.001584
2г	235824	419	235405	0.001777
2г 3 мес	217927	620	217307	0.002845
2г 6 мес	217927	586	206577	0.002829
2г 9 мес	188616	933	187683	0.004947
3г	165345	980	164365	0.005927
3г 3мес	132833	911	131922	0.006858
3г 6мес	109104	1057	108047	0.009688
3г 9мес	79764	692	79072	0.008676
4г	26992	190	26802	0.007039
4г 3мес	562	0	562	0.000000
4г 6мес	280	2	278	0.007143

оценка совокупного числа отказов дисков по всем системам выражается формулой 12.

$$\begin{cases} x_{i+1} = x_i * error_{i+1} & | i \in 1 \dots 17 \\ x_{i+1} = x_i * max(error_i : i \in 1 \dots 18) & | i > 17 \end{cases} \quad (12)$$

То есть, число отказов дисков x_i , функционирующих i кварталов, в квартале $i+1$, вычисляется как произведение количества дисков, функционирующих i кварталов и частоты отказа диска $error_{i+1}$ в $i+1$ квартале. В случае, если статистики об отказах диска в $i+1$ квартале нет, что верно, например, для дисков, функционирующих более, чем 4 года 6 месяцев (17 кварталов), в качестве частоты отказа за следующий $i+1$ квартал берется максимальная частота отказа за период работы диска.

Так как при использовании оценки 12 для дисков, функционирующих больше, чем 4 года 6 месяцев, время работы диска никак не учитывается и берется максимальная доля отказа, прогнозируемое количество отказов дисков, полученное по этой оценке, может быть завышено. Поэтому была представлена также некоторая оценка среднего числа дисков, которые могут отказать, которая определена аналогично предыдущей оценке и представлена в формуле 13.

$$\begin{cases} x_{i+1} = x_i * error_{i+1} & | i \in 1 \dots 17 \\ x_{i+1} = x_i * mean(error_i : i \in 1 \dots 18) & | i > 17 \end{cases} \quad (13)$$

В оценке 13 для дисков x_{i+1} , функционирующих дольше 17 кварталов, в качестве доли отказов в следующем квартале берется среднее долей отказов дисков $mean(error_i : i \in 1 \dots 18) | i > 17$ за все предыдущие кварталы. При таком формировании доли отказов дисков за новый квартал учитываются доли отказов за предыдущие кварталы.

С использованием приведенных оценок было рассчитано как общее число ожидаемых отказов дисков по всем системам хранения, так и число отказов дисков нескольких моделей, наиболее распространенных в системах хранения данных у пользователей. График 9 демонстрирует распространение различных моделей дисков в функционирующих

системах хранения.




Рис. 9: Распространение различных моделей дисков

Из представленного графика о распространении различных моделей дисков, можно отметить, что наиболее популярные модели — это модели дисков компании *Western Digital*: *HUH721212AL4204-C3F0* (используется более 100000 экземпляров) и *WUH721414AL4204-C130* (используется почти 60000 экземпляров). Из графика видно, что в компании *Yadro* используются диски компаний *Seagate* (названия моделей начинаются с *ST*) и *Western Digital* (названия моделей начинаются с *WUH/HUH*). Для вычисления количества отказов дисков определенной модели были отобраны модели, используемые в количестве более 10000 экземпляров, приведенные в таблице 14.

Ниже представлены графики 10, 11, 12 прогнозируемого числа отказов дисков на 2024 и 2025 годы: число отказов дисков определенных моделей, а также суммарное число отказов дисков по всем системам хранения данных. Из представленных графиков можно видеть, что суммарное количество отказов дисков по всем системам хранения данных составит не менее 1300 дисков за квартал, и может возрасти до порядка 2500 дисков. При использовании оценки 12 для прогнозирова-

Таблица 14: Количество дисков наиболее распространенных моделей

Модель	Число дисков
HUH721212AL4204-C3F0	115141
WUH721414AL4204-C130	58217
ST14000NM0048-E0Y2	37495
ST16000NM004J-EYR2	36218
WUH721816AL4204-C232	22439
ST14000NM002G-E0A2	17142
ST12000NM0038-E0Y2	14787
ST12000NM0027-E0Y2	13686

ния среди дисков самой распространенной модели *HUH721212AL4204* ожидается более 1000 замен дисков каждый квартал 2024-2025 годов, при использовании оценки 13 число замен дисков за квартал снизится с 800 до чуть менее 500. Среди дисков второй по распространению модели *WUH721816AL4204* компании *Western Digital* число отказов за квартал достигнет 900 в период с 2024-2025 при оценке по формуле 12. Так как диски компании *Seagate* менее распространены в системах хранения данных *Yadro*, число отказов дисков за квартал среди них будет ниже по сравнению с дисками *Western Digital*. Среди наиболее распространенных моделей *ST14000NM0048* и *ST16000NM004J* число отказов дисков за квартал составит до 150 дисков. Стоит отметить, что количество отказов дисков моделей *ST14000NM0048* и *ST16000NM004J* (150 дисков за квартал), примерно вчетверо меньше прогнозируемого максимума отказов среди дисков *HUH721212AL4204* (1000 дисков за квартал). Так как число дисков модели *HUH721212AL4204* составляет 115141, а число дисков модели *ST14000NM0048* составляет 37495 (а модели *ST16000NM004J* 36218 соответственно), можно отметить, что прогнозируемая частота отказа дисков модели *HUH721212AL4204* выше частоты отказа дисков модели *ST14000NM0048* или *ST16000NM004J*.




Рис. 10: Суммарное прогнозируемое число отказов дисков на 2024-2025гг.




Рис. 11: Прогнозируемое число отказов дисков для моделей *Western Digital* на 2024-2025гг.




Рис. 12: Прогнозируемое число отказов дисков для моделей *Seagate* на 2024-2025гг.

Заключение

В ходе выпускной квалификационной работы были выполнены следующие задачи:

- Проведен обзор предметной области и рассмотрены алгоритмы, реализующие такие подходы машинного обучения для прогнозирования отказа жесткого диска как:
 - Прогнозирование отказа жесткого диска с помощью решения задачи бинарной классификации;
 - Прогнозирование отказа жесткого диска с помощью решения задачи выявления аномалий;
 - Прогнозирование отказа жесткого диска с помощью кластеризации.
- Для анализа модельного набора данных применены следующие методы, рассмотренные в обзорной части работы:
 - Метод опорных векторов, случайного леса и K ближайших соседей в рамках решения задачи бинарной классификации;
 - Метод изолированного леса, выявления аномалий с использованием расстояния Махаланобиса в рамках решения задачи выявления аномалий;
 - Методы *KMeans*, *Bisecting KMeans*, *Spectral Clustering*, *Mean Shift*, *OPTICS* в рамках решения задачи кластеризации.
- На основе нескольких источников реальных данных был сформирован набор данных для диагностики отказа диска по его снимку *S.M.A.R.T.* параметров.
- Для выявления моделей поведения в сформированном наборе реальных данных применены алгоритмы кластеризации *DBSCAN*, *HDBSCAN*. Получившиеся в результате кластеры были визуализированы с помощью алгоритмов снижения размерности на двумерное пространство *PCA*, *t-SNE*, *UMAP*.

- На основании проведенного анализа имеющихся данных дисков можно сформулировать следующие рекомендации к прогнозированию отказов дисков:
 - Ненулевые значения параметров *Elements in grown defect list*, *Total uncorrected errors read*, *Total uncorrected errors write* могут свидетельствовать о поломке диска — 50.7% таких дисков ранее были помечены как отказавшие. Если каждый из приведенных параметров диска имеет нулевое значение, вероятно, диск функционирует нормально — отказы в таких случаях происходили всего в 15.6%.
 - При интерпретации значения параметра текущей температуры диска *Current Drive Temperature* учитывать разность предельной температуры диска *Drive Trip Temperature* для разных компаний-производителей — для дисков компании *Seagate* предельная температура 60C и для дисков компании *Western Digital* предельная температура 85C.
 - При возникающих ошибках дисков может иметь значение версия спецификации, в соответствии с которой реализован диск: большинство дисков компании *Western Digital* реализованы в соответствии со спецификацией *SPC-4*, большинство дисков компании *Seagate* реализованы в соответствии со спецификацией *SPC-5*.
- Построены максимальная и средняя оценка числа отказавших дисков на 2024-2025 годы. Оценено, что число отказавших дисков возрастет до 2500 за квартал к концу 2025 года.

Список литературы

- [1] Jiang Weihang, Hu Chongfeng, Zhou Yuanyuan, and Kanevsky Arkady. Are Disks the Dominant Contributor for Storage Failures? A Comprehensive Study of Storage Subsystem Failure Characteristics // [ACM Trans. Storage](#). — 2008. — nov. — Vol. 4, no. 3. — Access mode: <https://doi.org/10.1145/1416944.1416946>.
- [2] Baum Leonard E. and Petrie Ted. Statistical Inference for Probabilistic Functions of Finite State Markov Chains // [Annals of Mathematical Statistics](#). — 1966. — Vol. 37. — P. 1554–1563.
- [3] Breiman L. Random Forests // [Machine Learning](#). — 2001. — 10. — Vol. 45. — P. 5–32.
- [4] Ester Martin, Kriegel Hans-Peter, Sander Jörg, and Xu Xiaowei. A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise // [Knowledge Discovery and Data Mining](#). — 1996. — Access mode: <https://api.semanticscholar.org/CorpusID:355163>.
- [5] Di Jian and Gou Xinyu. Bisecting K-means Algorithm Based on K-valued Selfdetermining and Clustering Center Optimization // [J. Comput.](#) — 2018. — Vol. 13. — P. 588–595.
- [6] Fix Evelyn and Hodges Joseph L. Discriminatory Analysis - Nonparametric Discrimination: Consistency Properties // [International Statistical Review](#). — 1989. — Vol. 57. — P. 238.
- [7] Fowlkes E. B. and Mallows C. L. A Method for Comparing Two Hierarchical Clusterings // [Journal of the American Statistical Association](#). — 1983. — Vol. 78, no. 383. — P. 553–569. — <https://www.tandfonline.com/doi/pdf/10.1080/01621459.1983.10478008>.
- [8] Hamerly Greg and Elkan Charles. Bayesian Approaches to Failure Prediction for Disk Drives // [Proceedings of the Eighteenth International](#)

Conference on Machine Learning. — San Francisco, CA, USA : Morgan Kaufmann Publishers Inc. — 2001. — ICML '01. — P. 202–209.

- [9] Tomer Vikas, Sharma Vedna, Gupta Sonali, and Singh Devesh. Hard disk drive failure prediction using SMART attribute // [Materials Today: Proceedings](#). — 2021. — 04. — Vol. 46.
- [10] Hilbert Martin and López Priscila. The World's Technological Capacity to Store, Communicate, and Compute Information // [Science \(New York, N.Y.\)](#). — 2011. — 02. — Vol. 332. — P. 60–5.
- [11] Hubert Lawrence and Arabie Phipps. Comparing partitions // [Journal of Classification](#). — 1985. — Dec. — Vol. 2, no. 1. — P. 193–218. — Access mode: <https://doi.org/10.1007/BF01908075>.
- [12] Hughes Gordon, Murray Joseph, Kreutz-Delgado Ken, and Elkan Charles. Improved disk-drive failure warnings // [Reliability, IEEE Transactions on](#). — 2002. — 10. — Vol. 51. — P. 350 – 357.
- [13] Liu Fei Tony, Ting Kai Ming, and Zhou Zhi-Hua. [Isolation Forest](#) // 2008 Eighth IEEE International Conference on Data Mining. — 2008. — P. 413–422.
- [14] Lloyd Stuart P. Least squares quantization in PCM // [IEEE Trans. Inf. Theory](#). — 1982. — Vol. 28. — P. 129–136.
- [15] Morales-Forero A. and Bassetto S. [Case Study: A Semi-Supervised Methodology for Anomaly Detection and Diagnosis](#) // 2019 IEEE International Conference on Industrial Engineering and Engineering Management (IEEM). — 2019. — P. 1031–1037.
- [16] Murray Joseph, Hughes Gordon, and Kreutz-Delgado Ken. Hard drive failure prediction using non-parametric statistical methods. — 2003. — 01.
- [17] Murray Joseph F., Hughes Gordon F., and Kreutz-Delgado Kenneth. Machine Learning Methods for Predicting Failures in Hard Drives: A

Multiple-Instance Application // J. Mach. Learn. Res. — 2005. — dec. — Vol. 6. — P. 783–816.

- [18] Ankerst Mihael, Breunig Markus M., Kriegel Hans-Peter, and Sander Jörg. [OPTICS: Ordering Points to Identify the Clustering Structure](#) // Proceedings of the 1999 ACM SIGMOD International Conference on Management of Data. — New York, NY, USA : Association for Computing Machinery. — 1999. — SIGMOD '99. — P. 49–60. — Access mode: <https://doi.org/10.1145/304182.304187>.
- [19] Wang Yu, Miao Qiang, Ma Eden W. M., Tsui Kwok-Leung, and Pecht Michael G. Online Anomaly Detection for Hard Disk Drives Based on Mahalanobis Distance // [IEEE Transactions on Reliability](#). — 2013. — Vol. 62, no. 1. — P. 136–145.
- [20] Pitakrat Teerat, van Hoorn André, and Grunske Lars. [A comparison of machine learning algorithms for proactive hard disk drive failure detection](#). — 2013. — 06. — P. 1–10.
- [21] Zhao Ying, Liu Xiang, Gan Siqing, and Zheng Weimin. [Predicting disk failures with HMM- and HSMM-based approaches](#). — 2010. — 07. — Vol. 6171. — P. 390–404.
- [22] Zhu Bingpeng, Wang Gang, Liu Xiaoguang, Hu Dianming, Lin Sheng, and Ma Jingwei. [Proactive drive failure prediction for large scale storage systems](#) // 2013 IEEE 29th Symposium on Mass Storage Systems and Technologies (MSST). — 2013. — P. 1–5.
- [23] Garcia Marco, Ivanov Vladimir, Kozar Anastasia, Litvinov Stanislav, Reznik Alexey, Romanov Vitaly, and Succi Giancarlo. Review of techniques for predicting hard drive failure with SMART attributes // [International Journal of Machine Intelligence and Sensory Signal Processing](#). — 2018. — 01. — Vol. 2. — P. 151.
- [24] Rombach Philipp and Keuper Janis. [SmartPred: Unsupervised Hard Disk Failure Detection](#) // High Performance Computing: ISC High

Performance 2020 International Workshops, Frankfurt, Germany, June 21–25, 2020, Revised Selected Papers. — Berlin, Heidelberg : Springer-Verlag. — 2020. — P. 235–246. — Access mode: https://doi.org/10.1007/978-3-030-59851-8_15.

- [25] Sakurada Mayu and Yairi Takehisa. [Anomaly Detection Using Autoencoders with Nonlinear Dimensionality Reduction](#) // Proceedings of the MLSDA 2014 2nd Workshop on Machine Learning for Sensory Data Analysis. — New York, NY, USA : Association for Computing Machinery. — 2014. — MLSDA'14. — P. 4–11. — Access mode: <https://doi.org/10.1145/2689746.2689747>.
- [26] Schroeder Bianca and Gibson Garth A. Disk Failures in the Real World: What Does an MTTF of 1,000,000 Hours Mean to You? // Proceedings of the 5th USENIX Conference on File and Storage Technologies. — USA : USENIX Association. — 2007. — FAST '07. — P. 1–es.
- [27] Shlens Jonathon. A Tutorial on Principal Component Analysis. — 2014. — 1404.1100.
- [28] Tan Yongmin and Gu Xiaohui. [On Predictability of System Anomalies in Real World](#) // 2010 IEEE International Symposium on Modeling, Analysis and Simulation of Computer and Telecommunication Systems. — 2010. — P. 133–140.
- [29] Pereira Francisco Lucas F., Castro Chaves Iago, Gomes João Paulo P., and Machado Javam C. [Using Autoencoders for Anomaly Detection in Hard Disk Drives](#) // 2020 International Joint Conference on Neural Networks (IJCNN). — 2020. — P. 1–7.
- [30] Vapnik Vladimir. [The Nature of Statistical Learning Theory](#). — 2000. — 01. — P. 69–91. — ISBN: 978-1-4419-3160-3.
- [31] Vinh Nguyen Xuan, Epps Julien, and Bailey James. [Information Theoretic Measures for Clusterings Comparison: Is a Correction for Chance](#)

- [Necessary?](#) // Proceedings of the 26th Annual International Conference on Machine Learning. — New York, NY, USA : Association for Computing Machinery. — 2009. — ICML '09. — P. 1073–1080. — Access mode: <https://doi.org/10.1145/1553374.1553511>.
- [32] Wang Yu, Miao Qiang, and Pecht Michael. [Health monitoring of hard disk drive based on Mahalanobis distance](#) // 2011 Prognostics and System Health Management Conference. — 2011. — P. 1–8.
- [33] Zhou Chong and Paffenroth Randy C. [Anomaly Detection with Robust Deep Autoencoders](#) // Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. — New York, NY, USA : Association for Computing Machinery. — 2017. — KDD '17. — P. 665–674. — Access mode: <https://doi.org/10.1145/3097983.3098052>.
- [34] von Luxburg Ulrike. A Tutorial on Spectral Clustering. — 2007. — 0711.0189.